دانشگاه صنعتی نوشیروانی بابل
دانشکده مهندسی برق و کامپیوتر

پایان‌نامه کارشناسی رشته مهندسی کامپیوتر

# پیاده سازی و تحلیل یک مدل برای ارتباط دارو–هدف با استفاده از یادگیری عمیق

دانشجو:

کوروش یوسفیان ملا

استاد راهنما:

دکتر فاطمه زمانی

شهریور ۱۴۰۳


بسم الله الرحمن الرحيم

[این صفحه خالی است]

# چکیده

طراحی و توسعه دارو از گذشته تا به حال همواره با چالش های زیادی مانند زمان بر بودن، هزینه بر بودن و چالش های مرتبط با ایمنی دارو روبرو بوده است. drug repurposing یکی تکنیک هایی است که جهت مقابله با این چالش ها ارائه شده است.

در این روش، شناسایی اینکه داروی مد نظر روی چه پروتئین یا پروتئین های مربوط به عامل بیماری زا تاثیرگذار است، ضروری به نظر میرسد. این مسئله با عنوان پیش بینی ارتباط دارو-هدف نیز شناخته میشود. جهت حل این مسئله از روش هایی که مبتنی بر محاسبات اند استفاده شده است که از جمله آن ها میتوان به روش های مبتنی بر هوش مصنوعی و یادگیری عمیق اشاره کرد.

در این گزارش پروژه به معرفی یک شبکه عصبی عمیق تحت عنوان DTANet پرداخته میشود. این شبکه عصبی جهت پیش بینی ارتباط دارو-هدف بکار میرود و در درون خود از معماری های MLP، CNN و GraphKAN (مشتق شده از شبکه عصبی کولموگروف-آرنولد) استفاده میکند.

این شبکه عصبی توانسته است در متریک های ارزیابی مربوط به دو مجموعه داده از این مسئله، از تعدادی از معماری هایی پیشین مانند GraphDTA: GCN و WideDTA عملکرد بهتری را نشان دهد.

**در دسترس بودن اجرا:** مدل پیشنهادی در زبان برنامه نویسی پایتون و با کمک کتابخانه هایی از جمله PyTorch، PyTorch Geometric و کتابخانه های دیگر پیاده سازی شده است. داده های مرتبط، نتایج، مدل از پیش آموزش دیده و فایل های کدنویسی مربوطه در صفحه این پروژه در وبسایت گیت‌هاب به آدرس https://github.com/kourosh-y/DTANet منتشر شده است.

**کلمات کلیدی:** باز طراحی دارو ، ارتباط دارو-هدف ، یادگیری عمیق

[این صفحه خالی است]

# فهرست مطالب


**چکیده** **الف**

**۲ معرفی شبکه های عصبی KAN** **۱۰**

۲-۱ شبکه عصبی کولموگروف-آرنولد: KAN ..... **۱۰**

۲-۲ شبکه عصبی گرافی کولموگروف-آرنولد: GraphKAN ..... **۲۲**

**۳ روش پیشنهادی** **۲۵**

۳-۱ تشکیل بازنمایی دارو ..... **۲۵**

۳-۲ تشکیل بازنمایی پروتئین هدف ..... **۲۸**

۳-۳ پیش بینی میزان ارتباط با استفاده از بازنمایی ترکیبی ..... **۳۰**

۳-۴ جمع بندی معماری کلی DTANet ..... **۳۰**

**۴ پیاده‌سازی پروژه** **۳۲**

۴-۱ ساختار کلی کد پروژه ..... **۳۲**

۴-۲ روند اجرایی کد پروژه ..... **۳۳**

**۵ نتایج آزمایش‌ها** **۳۶**

۵-۱ معرفی مجموعه داده های معیار ..... **۳۶**

۵-۲ مقایسه نتایج مدل معرفی شده با دیگر مدل ها ..... **۳۶**

**۶ نتیجه گیری و ارائه پیشنهادها برای کارهای آینده** **۳۹**

**۷ مراجع** **۴۲**

# فهرست شکل ها


۱ روش کار SimBoost ..... ۳

۲ مدل KronRSL ..... ۴

۳ مدل DeepDTA ..... ۵

۴ مدل WideDTA ..... ۶

۵ مدل GraphDTA ..... ۹

۶ شبکه عصبی KAN پیشنهادی به افتخار آندری کولموگروف و ولادیمیر آرنولد ..... ۱۰

۷ مقایسه بین دو شبکه KAN و MLP ..... ۱۳

۸ توابع فعال‌سازی که در شبکه عصبی وجود دارند ..... ۱۴

۹ نمونه ای از نحوه انجام رگرسیون به صورت نمادین با KAN ..... ۱۸

۱۰ نمونه ای از مسئله یادگیری مستمر مجموعه داده یک کار رگرسیون ۱ بعدی با ۵ قله گاوسی ..... ۲۰

۱۱ KAN ها برای کارهای نمادین ساده قابل تفسیر هستند ..... ۲۱

۱۲ معماری و عملکرد شبکه عصبی GraphKAN ..... ۲۳

۱۳ مقایسه دقت تست و مصرف زمان شبکه های عصبی GCN و GraphKAN ..... ۲۴

۱۴ نمونه ای از الگوریتم تولید SMILES ..... ۲۸

۱۵ معماری شبکه عصبی DTANet ..... ۳۱


# فهرست جداول


۱ هایپرپارامتر های DTANet ..... ۳۷

۲ مقایسه میزان عملکرد مدل ها بر روی مجموعه داده Davis ..... ۳۸

۳ مقایسه میزان عملکرد مدل ها بر روی مجموعه داده Kiba ..... ۳۸

# فصل ۱

## مقدمه

در حـال حاضر هزینه طـراحی و توسـعه یک داروی جـدید در ایالات متحده آمریکا برابر حدوداً ۲.۶ میلیارد دلار تخمیـن زده شـده است [۱]. تایـید شدن آن نیز توسط سازمان غذا و داروی این کشور حدود ۱۷ سال به طـول می انجامـد [۲]. استـفاده مجدد از داروهای تایید شده توسط این دست از سازمان ها که به عنوان درمانی برای یک یا چند بیماری بخصوص بکار میروند، میتواند این فرآیند طراحی و توسعه را سرعت ببخشد [۳]. از مثال های مربوط به این روش میتوان به نزدیک به ۷۰ دارویی که توسط سازمان غذا و داروی آمریکا انـتخاب شـده و در مرحله تحقیق و بررسی قرار دارند اشـاره کرد، با این امید که بتوانند برای درمان بیماری هایی مانند کووید-۱۹ مفید باشند [۴].

به جهـت یافتـن کارکرد جدید یک داروی از پیش تایید شده برای یک بیماری بخصوص، لازم است تا میـزان تأثـیرپـذیری آن داروی بخصوص روی پروتئین هدف سنـجیده شـود. این پروتئین هدف در داخل ساخـتار آن عـامل بیـماری زا (سـلول سرطانی، باکتری یا عوامل دیگر) موجود است. این میـزان تأثیرپذیری میتـواند به صورت تـجربی با استـفاده از آزمایش های غربالگری با کارایی بالا بدست آید اما مسئله اینجاست که غالبا ایـن آزمایشات نیز هزیـنه بـر و وقت گیر است [۵].

علاوه بر ایـن، میلیون ها ترکـیبات دارویی یا شـبه دارویی و در مقـابل آن صـد ها پـروتئین هـدف وجود دارد که باعـث میشود تعـداد کل ارتباط های دارو-هدف بسیار زیاد باشد [۶]. به همین دلیل، استفاده از روش های مـحاسبـاتی جـهت پیـش بینـی سـریع تر و کـم هـزیـنه تر مـیـزان ارتـباط ایـن مـجمـوعـه داروها و پروتئین های هدف ضروری به نظر میرسد.

در مـطـالعات قبلی، روش‌هـای مـحاسـبـاتی مـتعددی برای پیش‌بینی تعاملات دارو-هدف (DTA) پیشنهاد شـده‌اند. در میان این رویکردها، اتصال مولکولی به دلیل توانایی آن در تخمین پیکربندی سه بعدی پایدار مجموعه دارو-هدف، اهمیت پیدا کرده است. این امر با شبیه‌سازی فعل و انفعالات فیزیکی و شیمیایی بین دارو (لیگاند) و پروتئین هدف از طریق یک تابع امتیازدهی به دست می‌آید که موقعیت‌های اتصال بالقوه را بـر اسـاس حـالات انرژی آنها رتبه‌بندی می‌کند. اتصال مولکولی به عنوان سنگ بنای طراحی منطقی دارو عمل مـی کند، زیـرا بینش هـای ارزشمندی را در مورد مکانیسم های مولکولی عمل دارو ارائه می دهد و به

شناسایی نامزدهای درمانی بالقوه کمک می کند.

با ایـن حـال، عـلیرغم سـودمـندی بالقوه اتصال مولکولی، محدودیت های قابل توجهی دارد. یکی از حـیاتـی تـرین الزامـات، در دسـترس بـودن ساختارهای کریستالی با وضوح بالا از پروتئین های هدف است. ایـن ساختارها اغلب از طریق تکنیک هایی مانند کریستالوگرافی اشعه ایکس یا میکروسکوپ کرایو الکترونی تعیین مـی شـوند، امـا همـیشـه بـرای هـر پروتئین مورد علاقه در دسترس نیستند. فقدان چنین اطلاعات سـاختـاری بـه شـدت کاربرد اتصال مولکولی را محدود می کند، به ویژه برای پروتئین های تازه کشف شده یـا ضعیـف. در نتیجـه، تکیه بر اتصال مولکولی به تنهایی ممکن است منجر به پیش‌بینی‌های غیربهینه شود یـا اسـتفـاده از آن را بـه اهـدافـی که بـه خـوبـی مـطالـعـه شـده‌انـد مـحـدود کنـد.

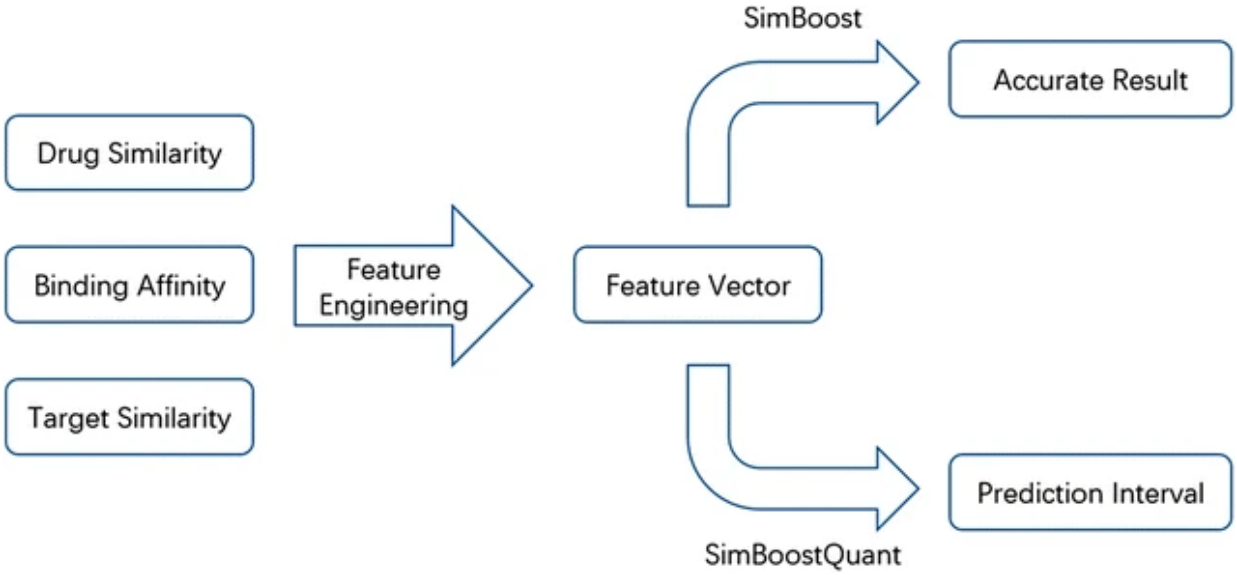
علاوه بر این، حتی زمانی که ساختار کریستالی در دسترس است، اتصال مولکولی محدودیت‌هایی در ثبت پیچیدگی کامل برهم‌کنش‌های مولکولی، مانند تغییرات ساختاری در پروتئین‌ها یا اثرات محیط زیستی اطـراف دارد. بنابراین، روش‌های جایگزین یا رویکردهای مکمل اغلب برای رسیدگی به این چالش‌ها و بهبود دقـت پیـش‌بینـی‌های تعامل دارو-هدف مورد نیاز است. این امر باعث شده است که تحقیقات در حال انجام بـرای تکنیک های همه کاره تر و مبتنی بر داده ها که صرفاً بر اطلاعات ساختاری متکی نیستند، انجام شود. [۷].

در میان رویکردهای مبتنی بر هوش مصنوعی برای پیش‌بینی تعاملات دارو-هدف، مدل SimBoost به عنوان یـک نمونه قابل توجه برجسته است. SimBoost از تکنیک یادگیری ماشینی معروف به Gradient Boosting بـرای پیـش‌بینـی بـر اسـاس شباهت‌های پیوند بین داروها و پروتئین‌های هدف استفاده می‌کند. SimBoost به جـای تکیـه بـر داده‌های ساختاری دقیق مانند اتصال مولکولی، بر یادگیری الگوها از داده‌های میـل تـرکـیبـی مـوجـود تـمرکز می‌کند. با مقایسه داروها و پروتئین‌ها با قرابت‌های شناخته‌شده، این مدل مـجموعـه‌ای از ویژگـی‌هـای جـدیـد و آموزنده را ایجاد می‌کند که روابط بین جفت‌های دارو-هدف را نشان می‌دهد. ایـن ویژگی‌ها ممکن است شامل خواص شیمیایی، الگوهای برهمکنش و معیارهای شباهت باشد که با هم یک ورودی قوی برای مدل تشکیل می‌دهند.

هنگامی کـه ایـن ویـژگی‌هـا سـاخته مـی‌شوند، بـه چارچوب تقویت گرادیان، یک تکنیک یادگیری گروهی قدرتمند که قدرت پیش‌بینی چندین یـادگیرنـده ضعیف، معمولا درخت‌های تصمیم‌گیری را ترکیب می‌کند، وارد مـی‌شوند. Gradient Boosting به طور مـکرر پیش بینـی هـای خود را با به حداقل رسـانـدن خطاها بهبود می بخشد و آن را در کشف روابط پیچیده و غیرخطی در داده ها بسیار موثر می کند. در زمینه پیش‌بینی دارو-هدف، این به SimBoost اجازه می‌دهد تا تعاملات ناشناخته را به طور مؤثر استنباط کند، حتی در مواردی که اطلاعات ساختاری صریح در دسترس نیست.

مدل SimBoost نمونه ای از روند رو به رشد ادغام الگوریتم های یـادگـیری مـاشین در فرآیندهای کشف دارو است. با استفاده از داده‌های میل ترکیبی موجود، برخی از محدودیت‌های روش‌هـای سنتی مانند اتصال مولکولی را دور می‌زند، به ویژه زمانی که ساختارهای پروتئینی به خوبی مـشخص نشـده باشند. علاوه بر این، توانایی پیش‌بینی تداخلات دارو-هدف براساس شباهت‌ها و یادگیری ویژگی‌ها، راه را بـرای تلاش‌های

غربـالـگری مجازی در مقیاس بزرگ باز می‌کند، شناسایی نامزدهای احتمالی دارو را تسریع می‌کند و کارایی کشف دارو در مراحل اولیه را بهبود می‌بخشد. [۸].



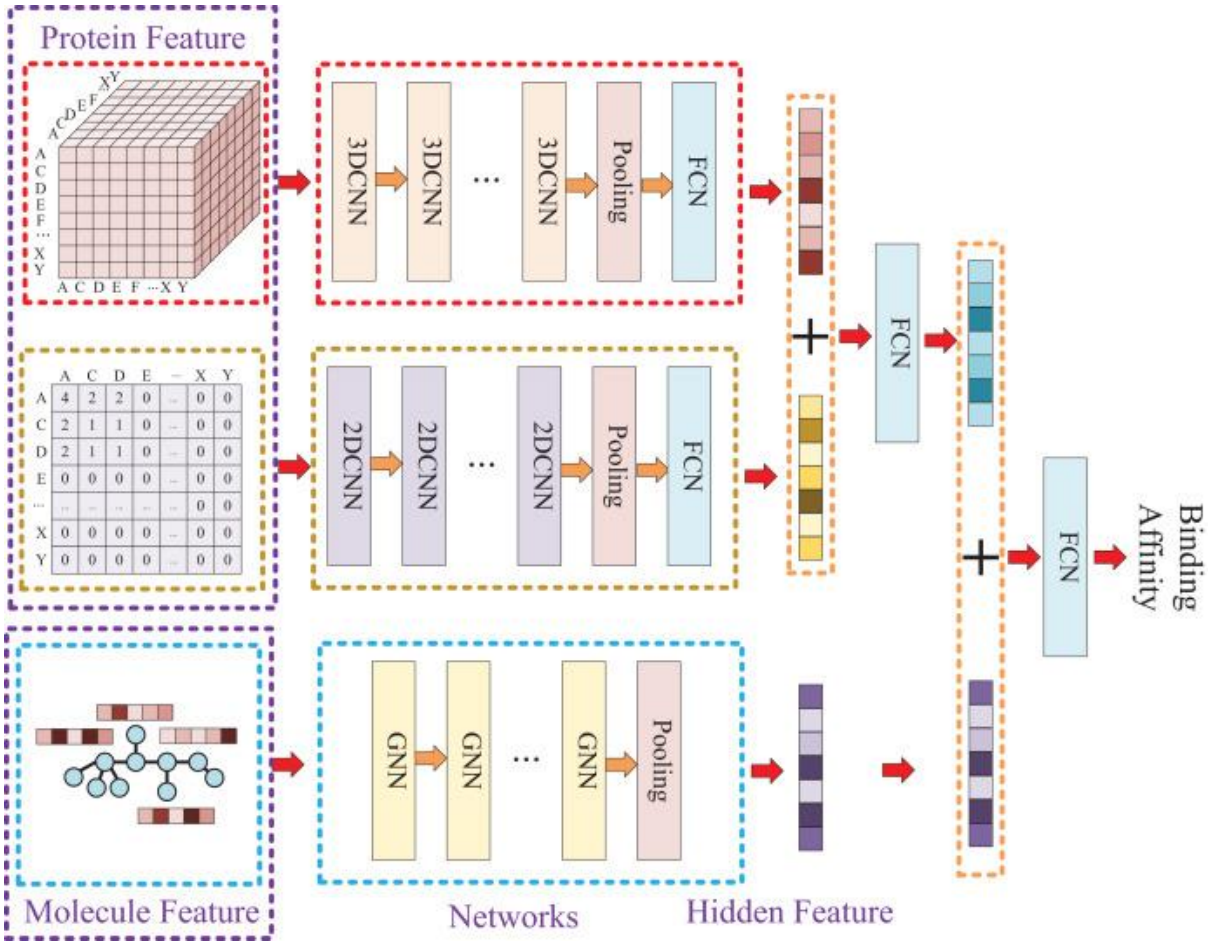

شکل ۱: روش کار SimBoost [۸]

از سوی دیـگر، روش‌هـای مبتنی بر شباهت می‌توانند اطلاعات مفیدی را از منابعی فراتر از نزدیکی داده‌های آموزشی به دست آورند. یکـی از رویـکردهای برجسته در این زمینه استفاده از روش‌های مبتنی بر کرنل است که شباهت‌های بین داروهـا و پـروتئیـن‌هـای هدف را با استفاده از خواص مولکولی آنها محاسبه می‌کند. این روش ها به جای تکیه بر نقاط داده مستقیم از مشاهدات قبلی، از توابع ریاضی به نام کرنل برای تعیین کمیـت روابـط بیـن مـولکول ها استفاده می کنند. این کرنل ها می‌توانند انواع مختلفی از ویژگی‌های مـولکولی، مانند ساختارهای شیمیایی، گروه‌های عملکردی، و الگوهای برهم‌کنش را به تصویر بکشند، و یک نمـایش ظـریف از شبـاهـت ایجـاد کنند که فراتر از مقایسه‌های سطحی است.

هنگامـی کـه ایـن کـرنـل های شباهت ساخته شدند، در چارچوب رگرسیون حداقل مربعات منظم (RLS) گنـجانـده می شـوند. روش RLS به ویژه مؤثر است زیرا دقت پیش‌بینی را با پیچیدگی مدل متعادل می‌کنـد. بـا بـه حـداقل رسـاندن خـطا بیـن فعـل و انـفعالات پیش‌بینی‌شده و مشاهده‌شده در حین اعمال منظم‌سازی برای جلوگیری از برازش بیش از حد، RLS تضمین می‌کند که این مدل نه تنها بر روی داده‌های شناخته‌شده به خوبی عمل می‌کند، بـلکه بـه طـور مـؤثری به جفـت‌هـای جدید و نادیده دارو-هدف تعمیم می‌دهد. استفاده از کرنل ها در ایـن چـارچـوب، مدل را قادر می‌سازد تا پیش‌بینی‌های آگاهانه‌ای را حتی در مواردی که داده‌های تجربی مستقیم کم یا ناقص هستند، انجام دهد، که استحکام فرآیند پیش‌بینی را بهبود می‌بخشد.

این رویـکرد مبتنی بـر کرنل دارای چندین مزیت است، به ویژه در توانایی آن در ادغام انواع مختلف داده هـای بیـولوژیکی و شیمیایی. بـا گرفتن ویژگی‌های مولکولی عمیق‌تر، کاربرد مدل‌های پیش‌بینی دارو-

هدف را به طیف وسیع‌تری از فعل و انفعالات گسترش می‌دهد. علاوه بر این، انعطاف‌پذیری توابع هسته اجازه می‌دهد تا روابط پیچیده و غیرخطی را در بر بگیرد، که اغلب برای پیش‌بینی دقیق بسیار مهم هستند. در نتیجه، این روش‌ها به توسعه مدل‌های قابل اعتمادتر و قابل تعمیم کمک می‌کنند و شناسایی نامزدهای دارویی امیدوارکننده در تحقیقات اولیه را تسهیل می‌کنند [۹].



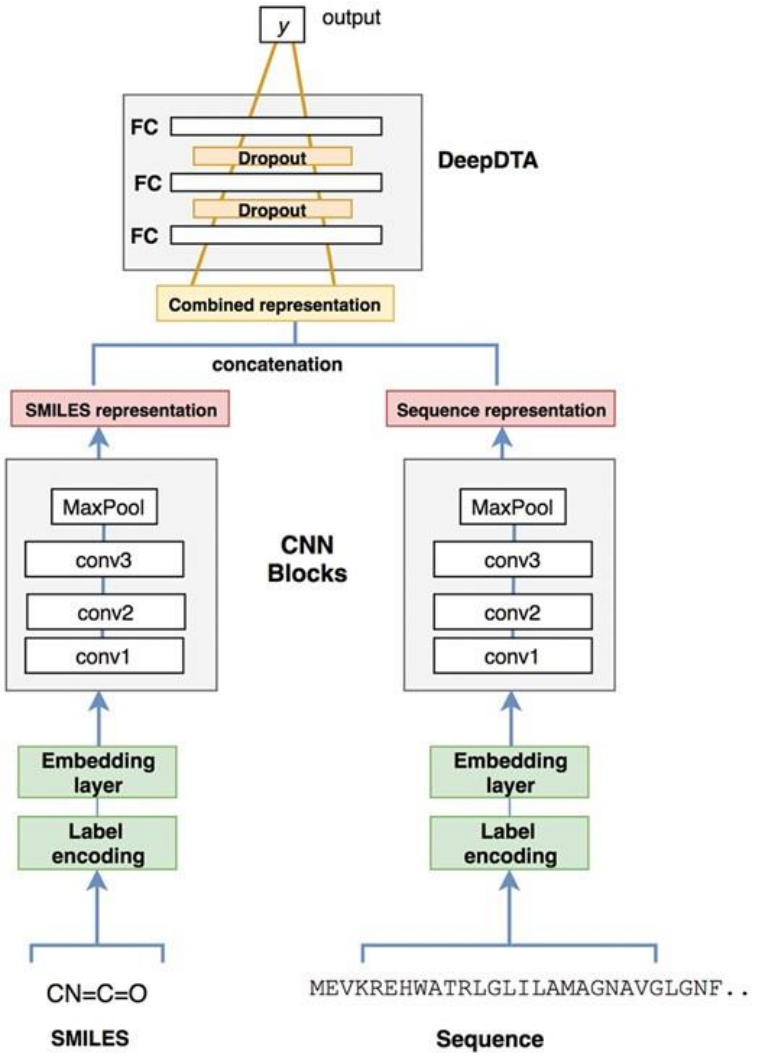

شکل ۲: مدل KronRSL [۹]

یکی دیگر از رویکردهای پیشرفته برای پیش‌بینی تعاملات دارو-هدف با استفاده از یادگیری عمیق، مدل DeepDTA است. برخلاف روش‌های سنتی که بر پایه اتصال مولکولی یا تکنیک‌های مبتنی بر شباهت تکیه می‌کنند، DeepDTA مستقیماً ویژگی‌های داروها و پروتئین‌های هدف را از توالی‌های خام آنها می‌آموزد. به طور خاص، ساختار مولکولی یک دارو به عنوان یک توالی یک بعدی، معمولاً به شکل SMILES (سیستم ورودی خط ورودی مولکولی ساده) نشان داده می شود، در حالی که پروتئین هدف با توالی اسید آمینه آن نشان داده می شود. این توالی ها به عنوان داده های ورودی خام برای مدل عمل می کنند و نیاز به دانش ساختاری قبلی یا مهندسی ویژگی را حذف می کنند.

DeepDTA از دو شبکه عصبی کانولوشنال مجزا (CNN) برای پردازش این توالی ها استفاده می کند. یک CNN به استخراج ویژگی‌های مرتبط از توالی دارو اختصاص دارد، در حالی که CNN دیگر ویژگی‌های مرتبط با پروتئین هدف را می‌آموزد. از طریق این لایه‌های CNN، مدل الگوهای مهمی مانند

زیرساخت‌های مولکولی در داروها و موتیف‌های عملکردی در پروتئین‌ها را به تصویر می‌کشد و به آن اجازه می‌دهد تا بازنمایی‌های معنی‌داری از هر دو موجودیت را بیاموزد. این ویژگی‌های استخراج‌شده سپس به نمایش‌های برداری تبدیل می‌شوند، که به عنوان شکلی از رمزگذاری عمل می‌کنند که ویژگی‌های کلیدی دارو و پروتئین را در بر می‌گیرد.

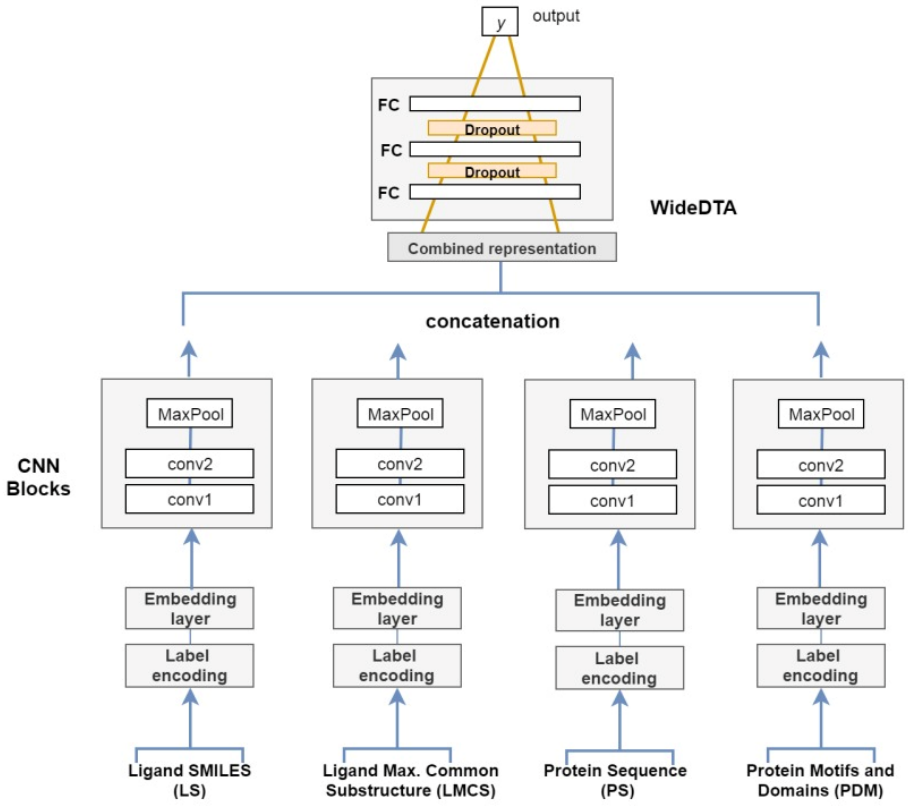
پس از به دست آوردن این بردارهای ویژگی، DeepDTA آنها را در یک نمایش واحد ترکیب می کند، که سپس از طریق یک شبکه عصبی پرسپترون چند لایه (MLP) منتقل می شود. MLP اطلاعات ترکیبی را پردازش می کند و یک خروجی نهایی تولید می کند، معمولاً یک مقدار عددی که قدرت یا احتمال تعامل دارو-هدف را نشان می دهد. این مقدار در یک بازه زمانی مشخص است، که معمولاً منعکس کننده میل پیوند پیش بینی شده یا امتیاز تعامل است. معماری یادگیری عمیق DeepDTA آن را قادر می‌سازد تا روابط بسیار پیچیده و غیرخطی بین داروها و پروتئین‌های هدف را مدل‌سازی کند، و آن را به ابزاری قدرتمند برای پیش‌بینی تعاملات بدون تکیه بر اطلاعات ساختاری از قبل موجود تبدیل می‌کند. [۱۰]. پس از منتشر شدن این روش، مدل WideDTA معرفی شد که در واقع بسطی از این روش است.




شکل ۳: مدل DeepDTA [۱۰]

مـدل WideDTA بـر اساس پـایه‌ای است که تـوسط DeepDTA ایـجاد شده است و پیشرفت‌های کلیدی را مـعرفی مـی‌کند که بـا تبدیـل توالی‌های خـام داروهـا و پروتئیـن‌ها به ویژگـی‌هـای مـعنی‌دارتـر و مرتبط‌تـر، فـرآیند یـادگیری را کارآمدتر می‌کند. WideDTA به جای تکیه صرفاً بر نمایش‌های توالی یک بعـدی، الگوهـای سـاختاری را شناسایی و ترکیب می‌کند که نقش مهمی در تعاملات دارو-هدف دارند. برای داروها، این امر با شناسایی رایج‌ترین زیرساخت‌ها، به‌عنوان زیرساختارهای مشترک لیگاند حداکثر (LMCS) بـه دسـت می‌آید. این زیرساخت‌ها اغلب در لیگاندهای مختلف یافت می‌شوند و نشان‌دهنده نقوش شیمیایی مهمی هستند که احتمالاً در تعاملات اتصال دخیل هستند. با استفاده از LMCS به عنوان بازنمایی از داروها، این مـدل مـی‌تواند بهتر بر روی مرتبط‌ترین اجزای شیمیایی تمرکز کند و توانایی آن را برای پیش‌بینی فعل و انفعالات بهبود بخشد.

برای پروتئیـن‌ها، WideDTA بـا استفاده از پروفیل‌های دامنه پروتئین یا موتیف‌های حفاظـت‌شده که از نظر عملکردی مهم هستنـد، رویکرد مشابهی را اتخاذ می‌کنـد. ایـن نقوش از پایگاه‌های داده‌ای مـانند PROSITE به دست می‌آیند که دامنـه‌های پروتئینی را فهرست‌بنـدی می‌کند که به دلیل نقش‌های اساسی در فرآینـدهـای بیـولوژیکی در بیـن گونه‌ها بسیار حفاظت شده‌اند. با استفاده از این حوزه‌های حفاظت‌شده، WideDTA می‌تواند ویژگی‌های عملکردی پروتئین‌ها را بهتر به تصویر بکشد، و این مدل را قادر می‌سازد بـر مـناطقی که احتمالاً در تعامل با داروها درگیر هستند تمرکز کند. این نمایش اختصاصی دامنه به مدل اجازه می‌دهد تا با دقت بیشتری پیش‌بینی کند که دارو به چه میزان به یک هدف پروتئینی خاص متصل می‌شود، حتی در غیاب داده‌های ساختاری دقیق.




شکل ۴: مدل WideDTA [۱۲]

تبدیـل توالی‌های خام به این ویژگی‌های پیچیده‌تر و بیولوژیکی‌تر، WideDTA را قادر می‌سازد تا از مدل‌هـایی که صـرفاً بـه داده‌های توالی متکی هستند، ماننـد DeepDTA، بهتـر عمـل کنـد. بـا تمـرکز بـر مرتبـط‌تـریـن زیرساخت‌های داروها و پروتئین‌ها، این مدل نویز را از مناطق کمتر مهم توالی کاهش می‌دهد و منجر به پیش‌بینی‌های دقیق‌تـر و قـابل تفسیر می‌شود. این بهبود به WideDTA اجازه می دهد تا در بین جفت های مختلف دارو-هدف بهتر تعمیم یابد و کاربرد آن را در کـشف دارو افزایـش مـی دهد، جـایی کـه شناسایی تعاملات اتصال کلیدی برای توسعه درمان های جدید حیاتی است. [۱۲].

دو مـدل DeepDTA و WideDTA تا سـال ۲۰۱۸ به عنوان بهترین مدل هایی که میتوانند ارتباط دارو-هدف را با میزان خطای کمتری نـسبت به بـقیه رویـکرد ها پـیش بینی کنند شـناخته میشدند [۱۳]. پـس از ایـن دو مـدل، در طـی انـتشار پـژوهشی، یـک مـدل جدید با رویـکرد مبتنی بر گراف تحت عنوان GraphDTA مـنتشر شـد.

ایده اصلی پشت مدل GraphDTA این است که نشان دادن ساختار داروها و پروتئین های هدف به صورت توالی های یک بعدی، همانطور که در مدل های قبلی مانند DeepDTA انجام مـی شد، ممکن اسـت به اندازه کافی پیچیدگی ساختار شیمیایی آنها را نشان ندهد. تـوالی هـای تک بعدی مـانند SMILES برای داروها و زنجیره هـای اسید آمینه برای پروتئین ها نمایش های خطی را ارائه می دهند، اما اغلب جنبه های مهم برهمکنش های مولکولی را که از آرایش فضایی و توپولوژیکی اتم ها و پیوندها ناشی مـی شود، از دست مـی دهند. این تفـاوت‌هـای سـاختـاری برای درک اینکه چگونه یک دارو ممکن است با پروتئین هدف خود تداخل داشته باشد ضروری است، و حذف آنها در روش‌های مبتنی بر توالی، توانایی مـدل را بـرای یـادگیری کامل و پیش‌بینی قدرت تداخلات دارو-هدف محدود می‌کند.

برای پرداختـن به این موضوع، GraphDTA از استفاده از نمایش‌های مبتنی بر توالی به نمایش‌های ساختاری دقیق‌تر، به‌ویژه برای داروها تغییر می‌کند. در ایـن مـدل، هـر دارو به عنوان یک نمودار نشان داده می شود که در آن گره ها نشان دهنده اتم ها و لبه ها نشان دهنده پیوندهای شیمیایی هستند. این نمایـش مبتنی بر نمودار به مدل اجازه می‌دهد تا ساختار مولکولی را به روشی شهودی‌تر به تصویر بکشد، و اتصـالات و روابط فضایی را که برای پیش‌بینی تعامل حیاتی هستند حفظ کند. فـرآیند یـادگیری تـوسط یـک شبـکه عصبی گراف (GNN) تسهیل می‌شود که به طور خاص برای کار با داده‌های ساختاریافته طراحی شده است. شبکه‌های عصبی نمودار، مانند GCN (شبکه‌های کانولوشن گراف)، GAT (شبکه‌هـای توجه گـراف) و GIN (شبکه‌های ایزومورفیسم نمودار)، قادر به یادگیری روابط پیـچیده و غیرخـطی بیـن گره‌هـا (اتم‌ها) و یال‌هـا (پیوندها) هستند.

در ساختار مولکولی دارو، این شبکه‌های عصبی مبتنـی بـر نـمودار بسیـار قـدرتمنـد هـستند زیـرا می‌تـوانند اطلاعـات را در سراسر گره‌ها منتشر کنند و یاد بگیرند که چگونه محیط محلی یک اتم (به عنوان مثال، اتم‌ها و پیوندهای همسایه آن) بر خواص کلی دارو تأثیر می‌گذارد. با استخراج این ویژگی‌ها از نمـودار، GraphDTA می‌تـوانـد نمـایش‌هـای دقیق‌تـر و مرتبط‌تـری از ساختـار شیمیایـی دارو بیـاموزد، که منـجر بـه پیش‌بینی‌های دقیق‌تری از نحوه تعامل آن با پروتئین هدف می‌شود.

با این حال، برای پروتئین های هدف، این رویکرد مبتنی بر نمودار به دلیل پیچیدگی و اندازه ساختارهای پروتئینی اعمال نشده است. درعوض، مدل همچنان به بازنمایی‌های سنتی مبتنی بر توالی برای پروتئین‌ها، مشابه روش‌های قبلی، تکیه می‌کند. در حالی که این محدودیت وجود دارد، بهبود نمایش دارو از طریق یادگیری نمودار به طور قابل توجهی عملکرد GraphDTA را در پیش‌بینی فعل و انفعالات دارو-هدف افزایش داده است، زیرا این مدل اکنون می‌تواند اطلاعات شیمیایی مرتبط‌تری را که روش‌های مبتنی بر توالی نادیده می‌گیرند، دریافت کند.

در ادامه توضیحاتی در مورد سازوکار شبکه عصبی های گرافی بکار رفته در مدل GraphDTA میدهیم.

شبکه ایزومورفیسم گراف (GIN) یک شبکه عصبی گراف است که برای دستیابی به سطح بالاتری از بیان در تمایز بین ساختارهای گراف طراحی شده است. GNNهای سنتی گاهی اوقات نمی‌توانند بین توپولوژی‌های گراف خاص تمایز قائل شوند، اما GIN با یادگیری توابع تزریقی که نقشه‌برداری مؤثرتر بین گره‌ها و همسایگی‌هایشان را تضمین می‌کند، به این موضوع می‌پردازد. در GIN ، هر گره از طریق یک تابع به‌روزرسانی انعطاف‌پذیرتر، اطلاعات همسایگان خود را جمع‌آوری می‌کند و به آن اجازه می‌دهد تا تفاوت‌های ساختاری ظریف در نمودارهای مولکولی را بهتر ثبت کند.

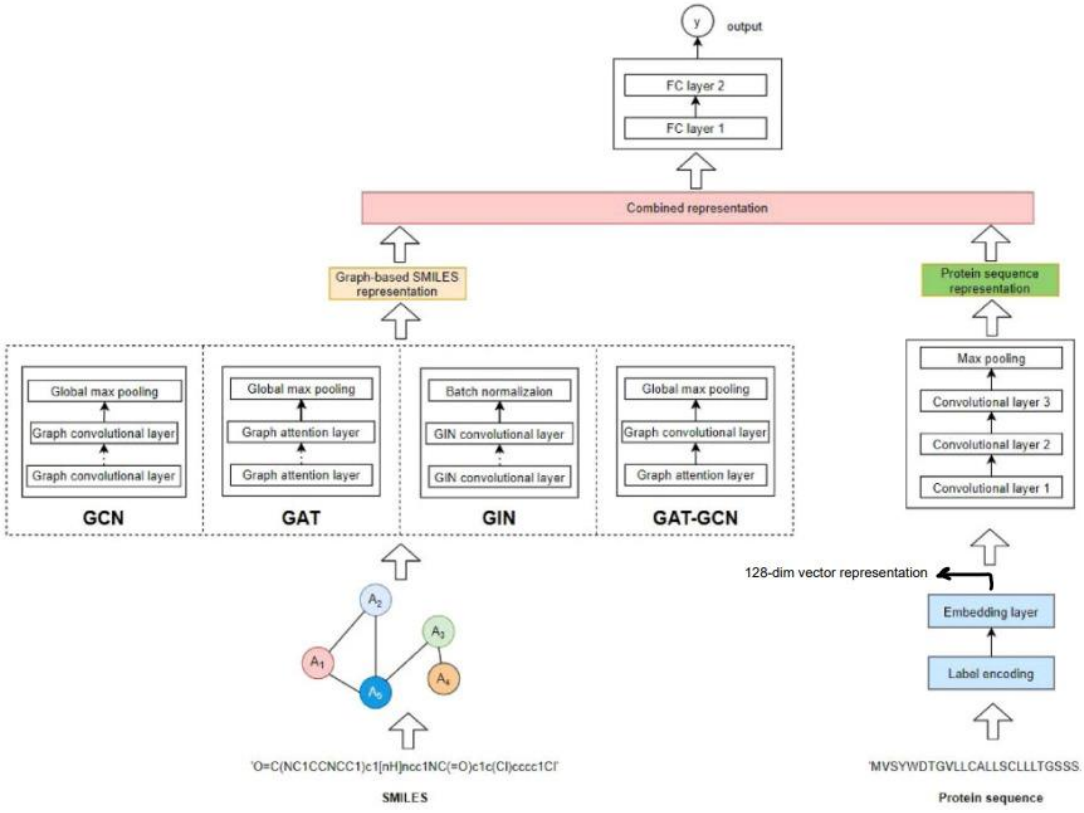
در زمینه GraphDTA ، GIN به ویژه مفید است زیرا در تشخیص زیرساخت‌های مولکولی مشابه و در عین حال متمایز برتری دارد، که برای پیش‌بینی دقیق اینکه چگونه تفاوت‌های کوچک در آرایش مولکولی می‌تواند بر اثربخشی دارو تأثیر بگذارد بسیار مهم است. با گرفتن این دانه بندی، GIN به GraphDTA کمک می کند تا ویژگی های غنی تر و متمایزتر از نمودار مولکولی دارو را بیاموزد، که منجر به پیش بینی های تعامل دقیق تر می شود.

شبکه کانولوشن گراف (GCN) یکی از پرکاربردترین معماری ها برای یادگیری مبتنی بر گراف است. با تعمیم عملیات کانولوشن سنتی به ساختارهای گراف کار می کند. در GCN ، هر گره ویژگی‌های گره‌های همسایه‌اش را با استفاده از یک مجموع وزنی جمع‌آوری می‌کند و به طور موثر اطلاعات را در نمودار ارسال می‌کند. این فرآیند تجمیع به صورت تکراری در سراسر لایه ها انجام می شود و به مدل اجازه می دهد تا نمایش های انتزاعی و فزاینده ای از نمودار را یاد بگیرد.

در GraphDTA، از GCN ها برای ثبت خواص ساختاری داروها، رمزگذاری اطلاعاتی مانند انواع اتم ها، پیوندها و محیط محلی هر اتم در نمودار مولکولی استفاده می شود. توانایی GCN برای ادغام اطلاعات ساختاری محلی و جهانی آن را برای یادگیری برهمکنش های پیچیده و چند سطحی موجود در مولکول های دارو، که مستقیماً بر پتانسیل اتصال آنها با پروتئین های هدف تأثیر می گذارد، ایده آل می کند.

شبکه توجه گراف (GAT) قابلیت‌های GCN را با ترکیب مکانیزم توجه گسترش می‌دهد، که به مدل اجازه می‌دهد تا میزان اهمیت دادن به هر گره همسایه را در طول فرآیند تجمع، بیاموزد. GAT به جای اینکه با همه همسایگان به طور مساوی رفتار کند، وزن‌های متفاوتی را بر اساس ارتباط آن‌ها به لبه‌های مختلف اختصاص می‌دهد که توسط امتیازات توجه تعیین می‌شود. این به مدل انعطاف‌پذیری بیشتری در تمرکز بر مهم‌ترین بخش‌های نمودار می‌دهد و آن را قادر می‌سازد تا به طور مؤثرتری از داده‌ها یاد بگیرد.

در GraphDTA، GAT ها به ویژه هنگام برخورد با نمودارهای مولکولی که در آن اتم ها یا پیوندهای خاص ممکن است نقش مهم تری در پیوند پیوند دارو نسبت به سایرین داشته باشند، مفید هستند. با استفاده از توجه، GAT می‌تواند این بخش‌های کلیدی ساختار دارو را برجسته کند، و اطمینان حاصل کند که مدل توجه بیشتری به ویژگی‌هایی دارد که بیشترین پیش‌بینی قدرت تعامل را دارند. این باعث می‌شود پیش‌بینی‌های تعامل دارو-هدف نه تنها دقیق‌تر، بلکه قابل تفسیرتر باشد، زیرا این مدل می‌تواند شناسایی کند که کدام زیرساخت‌های مولکولی خاص برای اتصال مهم‌تر هستند [۱۴].




شکل ۵: مدل GraphDTA [۱۴]

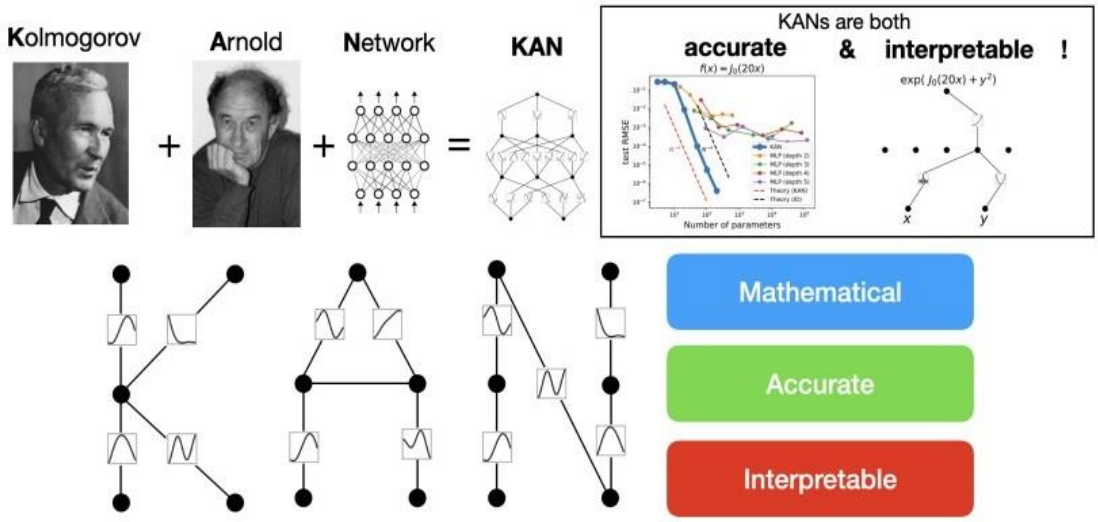
در ادامه این گزارش، به معرفی شبکه عصبی DTANet پرداخته می‌شود. در معماری این مدل، جهت یادگیری گراف مربوط به دارو از شبکه عصبی گرافی کولموگروف-آرنولد استفاده می‌شود. معماری کلی DTANet برگرفته از GraphDTA است و توانسته است نسبت به بیشتر مدل های پیش از خود عملکرد بهتری را نشان دهد.

# فصل ۲

# معرفی شبکه های عصبی KAN

در این فصل به معرفی شبکه کولموگروف-آرنولد (KAN) می‌پردازیم و سپس شبکه گرافی کولموگروف-آرنولد (GraphKAN) را به عنوان نسخه ای مشتق شده از آن که در معماری کلی DTANet بکار رفته است، توضیح میدهیم.

## ۲-۱ شبکه عصبی کولموگروف-آرنولد: KAN




شکل ۶: شبکه عصبی کولموگروف-آرنولد پیشنهادی به افتخار دو ریاضیدان بزرگ،
آندری کولموگروف و ولادیمیر آرنولد. [۱۵]

شبکه Kolmogorov-Arnold (KAN) یک معماری نوآورانه ارائه می دهد که به عنوان یک جایگزین بالقوه برای پرسپترون چند لایه سنتی (MLP) مورد استفاده در شبکه های عصبی طراحی شده است. برخلاف MLP ها که از وزن های خطی ثابت و به دنبال آن توابع فعال سازی غیر خطی استفاده می کنند، KAN ها این وزن های خطی را با توابع تک متغیره قابل یادگیری جایگزین می کنند. این تغییر به مدل اجازه می‌دهد تا روابط پیچیده بین ویژگی‌های ورودی را به شیوه‌ای انعطاف‌پذیرتر و سازگارتر ثبت کند و اتکا به تبدیل‌های خطی صلب را کاهش دهد. این توابع تک متغیره می توانند به صورت پویا در طول آموزش تنظیم شوند و منجر به نمایش دقیق تری از الگوهای داده های اساسی شوند.

KAN ها مـزایای قابل توجـهی نسبت به MLP ها دارند، به ویژه هنگامی که در شبکه های عصبی گراف (GNN) استفاده می شوند. یکی از مزایای کلیدی توانـایی آنها در بهبود کارایی و تفسیرپذیری فرآیند یادگیری است. MLP ، در حالی که موثر هستند، اغلب با چالش‌هـایی بـا تنگنـاهـای اطلاعـاتی و شفـافیت محدود در نحوه رسیدن به پیش‌بینی‌ها مواجه هستند. در مقابل، KAN ها با تفسیرپذیرتر کردن تبـدیل هـا به این مسائل می پردازند، زیرا توابع تک متغیره اجازه می دهد تا درک واضح تری از نحوه کمک هر ویـژگی ورودی به خروجی نهایی داشته باشیم.

علاوه بر ایـن، KAN ها همچنین یک مشکل حیاتی را که اغلب در MLP ها با آن مواجه مـی شود حل می کنند - از دست دادن اطـلاعات به دلیـل استفاده از تـوابع فعال سـازی مـانند ReLU یا sigmoid. این توابع فعال‌سازی می‌تواند مـنجر به ناپدید شدن یا انفجار مشکل گرادیان شود، جایی کـه اطلاعات مـهم در طول فرآیند یادگیری کاهش یا اغراق می‌شود. با اجتناب از نیاز به چنین عملکردهای فعال سازی، KAN ها اطلاعات ورودی اصلی را در سراسر شبکه حفظ می کنند، که مـنجر به پیش بینی های قوی تـر و دقـیق تر، به ویژه در برنامه های مبتنی بر GNN می شود.

مـفهوم اصـلی شبکـه کلـموگروف-آرنولد (KAN) از قضیه نمایش کولموگروف-آرنولد، یـک نتیـجه اساسی در ریاضیات، مشتق شده است. این قضیه بیان می کند که هـر تابع پیوسته چند متغیره تعریف شده در یک دامنه محدود می تواند به صورت ترکیبی محدود از توابع تک متغیره پیوسته و عملیات جـمع باینری بیان شود. به طور خاص، اگر f تابعی پیوسـته از چندین مـتغیر باشد، می توان آن را به مـجموع تـوابع یـک متغیر تجزیه کرد. این تجزیه نشان می‌دهد که روابـط پیـچیده چـند مـتغیره را می‌توان به اجزای ساده‌تری تقسیم کرد که هر کدام فقط به یک متغیر بستگی دارد.

در زمینه KAN ها، این قضیه زیربنای نظری را برای جـایگزینی وزن های خـطی سـنتی در شـبکه های عصبی با توابع تـک متغیره قـابل یادگیری فراهم می کند. به جای نمایش روابط پیچیده بین ورودی ها از طریق ضرب ماتریس و توابع فعال سازی، KAN ها به طور مستقیم این نگاشت هـای تک متغیره را بـرای هـر ویـژگی ورودی یاد می گیرند. نتیجـه یـک شبکـه انـعطاف پذیرتر اسـت که وابستگی های پیچیده بین متغیرها را به طور موثرتر و با محدودیت های کمتر مدل می کند.

با استفاده از قضیه کلموگروف-آرنولد، KAN ها می توانند توابع با ابعاد بالا را به گونه ای مدل کنند که دقت ریاضی را حفظ کند و در عین حال تفسـیرپذیری و کـارایی فرآیند یـادگیری را بهبود بـخشد. ایـن رویـکرد مـحدودیت‌های معماری‌های سنتی MLP را نادیده می‌گیرد و KANها را به یک جایگزین قدرتمند تبدیل می‌کند، به ویژه در کارهایی که روابـط پیـچیده ورودی-خروجی کلیدی هسـتند، مـانند شبـکه‌هـای عصبـی گـراف (GNN).

$$f(\boldsymbol{X}) = f(x_1, \ldots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \left( \sum_{p=1}^{n} \phi_{q,p}(x_p) \right)$$

$$f: [0,1]^n \rightarrow \mathbb{R} \ and \ \phi_{q,p} : [0,1] \rightarrow \mathbb{R} \ and \ \Phi_q : \mathbb{R} \rightarrow \mathbb{R}$$

قضیــه کولموگروف-آرنولد نشان مــی دهد که در اصل، تنها تابع چند متغیره واقعی جمع است، زیرا هـر تـابع چند متغیره دیگری را می توان به ترکیبی از توابع تک متغیره و عملیات جمع دودویی تجزیه کرد. این بینش اساس طراحی شبکه کولموگروف-آرنولد (KAN) را تشکیل می دهد. با الهام از این قضیه، KAN رویکردی اساسی متفاوت از شبکه‌های عصبی سنتی مانند MLP دارد. در KAN ، هـر ورودی ابتـدا از طریق یـک تـابـع فعـال سـازی قـابل یـادگیـری پـردازش مـی شود که بـا نشـان داده شـده اسـت

$\phi\,(\mathrm{x})$ ، قبل از اینـکه در گره هـا بـا هم جمع شوند. این استفاده از توابع تک متغیره قابل یادگیری برای نشان دادن ورودی ها، کاربرد مستقیم اصل قضیه است و به شبکه اجازه می دهد تا تعاملات پیچیده را با اجزای ساده تر مدل کند.

برخلاف MLP ها که به شدت به وزن های خطی و ضرب های ماتریس متکی هستند، KAN نیاز به پارامترهای صریح یا وزن های سنتـی را از بیـن مـی بـرد. در واقـع، عنـاصری کـه در طـول فـرآیند انتـشار پس‌پشتی بهینه می‌شوند، خود توابع فعال‌سازی قـابل یـادگیری $\phi\,(\mathrm{x})$ هسـتند. ایـن تـوابـع کـه بـه عنوان نگاشت‌های انعطاف‌پذیر ورودی‌ها عمل مـی‌کنند، نقش دوگانه دارند: نه تنها ورودی‌هـا را به شکلی تبـدیـل می‌کنند که شبکه بتواند از آن برای یادگیری استفاده کند، بلکه به عنوان پارامترهای قابل تنظیم (یا وزن‌ها) نیز عمل مـی‌کنند. شـبکه هـمانطور کـه مدل آموزش می بیند، توابع سازگار می شوند و توانایی شبکه برای نمایش دقیق روابط پیچیده بین ویژگی های ورودی و خروجی را بهبود می بخشد.

این معماری مزیت قابل توجهی نسبت به MLP ها از نظر انعطاف پذیری و دقت دارد. در حالی که MLP هـا وزن‌های ثـابت را بـرای تبدیـل ورودی‌هـا یاد می‌گیرند، شبکه‌های KAN با بهینه‌سازی پویا خود فرآیند تبدیل از طریق توابع فعال‌سـازی قابل یادگیری، یـک قدم فراتر مـی‌روند. این به شبکه KAN اجـازه می‌دهد تا نه تنها ویژگی‌های مرتبط را از داده‌ها یاد بگیرد، بلکه آن ویژگی‌ها را بـا دقت بـالا تنظیم کند. در نتیجه، KAN هـا برای کارهایی که هم نیاز بـه اسـتخراج ویژگی و هم بهینه سـازی دارند، مـناسب هـستند و جایگزین قدرتمندتری برای معماری های پیشخور سنتی ارائه مـی کنند. در شکل (۱) مقایسه ای تصویری بین دو شبکه KAN و MLP ارائه شده است.

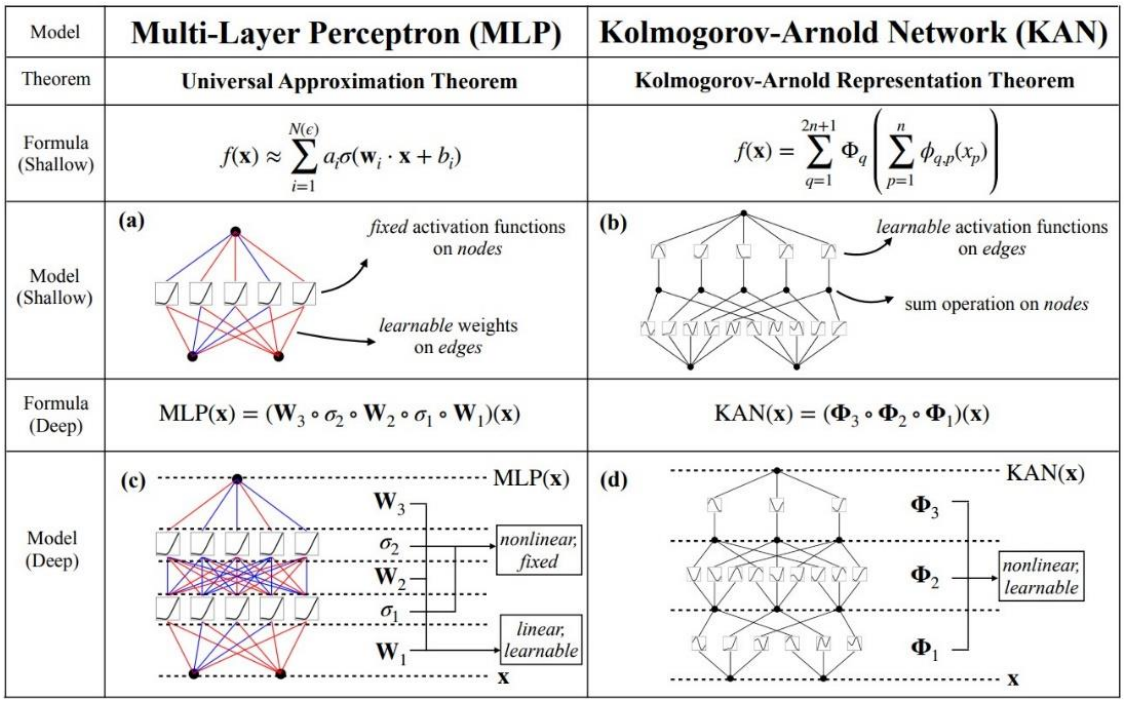
لازم بـه ذکـر اسـت که مطابـق آنچه از قضیه مطرح شده می‌تـوان نتیـجـه گـرفت، این شبـکه صرفا در دو لایـه و $2n+1$ تعـداد تـابع در هـر لایـه خلاصـه شده است ولـی در مـدل KAN این رابـطه بـه گونـه ای گسترش داده شده است که مـی‌تواند به عمق و عرض دلخواه بسط پیدا کند بنابراین برای هر لایه از این مدل با ورودی هایی به ابعاد $n_{in}$ و خروجی هایی به ابعاد $n_{out}$ میتوان نوشت:

$$\boldsymbol{\Phi} = \{\phi_{q,p}\}, \quad p = 1, 2, \ldots, n_{in}, \quad q = 1, 2, \ldots, n_{out}$$

و در صورتـی کـه تعداد لایه های شبکه $L$ فرض شود میتوان نوشت:

$$KAN(x) = (\boldsymbol{\Phi}_{L-1} \circ \boldsymbol{\Phi}_{L-2} \circ \ldots \circ \boldsymbol{\Phi}_1 \circ \boldsymbol{\Phi}_0)x$$

اکنون سـوالی که مطرح می شود این است که این توابع فعال‌سازی به چه صورت هستند و در حین بهینه سازی، چگونه تغییر میکنند.




شکل ۷: مقایسه بین دو شبکه KAN و MLP [۱۵]

در رابطه مربوط به هر تابع فعال سازی این شبکه به صورت زیر هستند:

$$\phi(x) = \omega_b b(x) + \omega_s spline(x)$$

$$b(x) = silu(x) = \frac{x}{1 + e^{-x}}$$

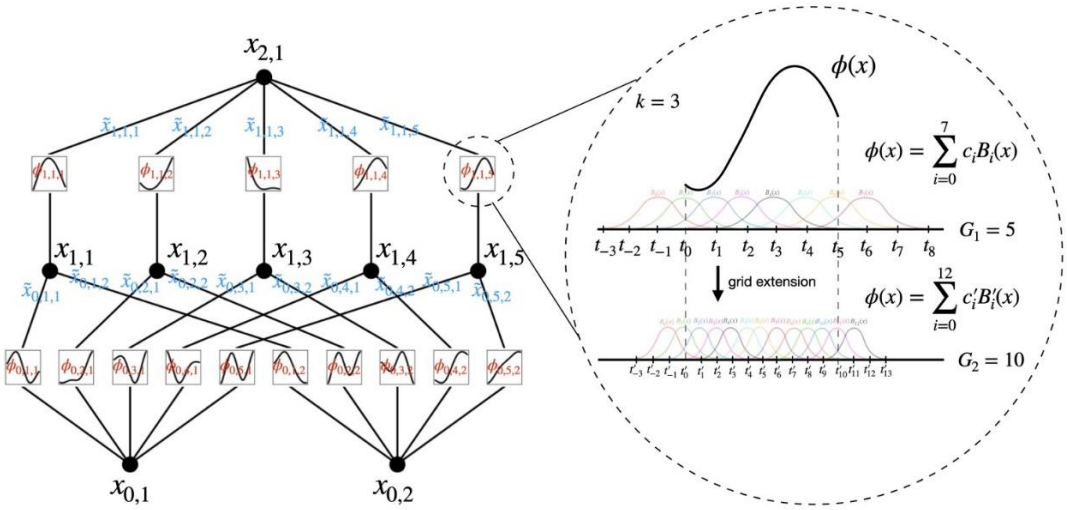
$$spline(x) = \sum_i c_i B_i(x)$$

در طراحی تابع فعال‌سازی $\varphi(x)$ برای شبکه Kolmogorov-Arnold (KAN)، پارامتر $ci$ به عنوان مؤلفه کلیدی قابل یادگیری نقش اصلی را ایفا می‌کند. این پارامتر در طول فرآیند آموزش به صورت پویا تنظیم می شود و به شبکه اجازه می دهد تا عملکرد فعال سازی را برای هر ویژگی ورودی بهینه کند. در حالی که $\omega b$ و $\omega s$ نیز پارامترهایی هستند که می توان آنها را یاد گرفت، آنها اغلب توسط دو تابع دیگر، $spline(x)$ و $b(x)$ جذب می شوند و به طور موثر پیچیدگی معادله را کاهش می دهند. با این حال، $\omega b$ و $\omega s$ برای کنترل بهتر بر بزرگی کلی و مقیاس‌بندی تابع فعال‌سازی حفظ می‌شوند و انعطاف‌پذیری را در تنظیم نحوه پاسخ شبکه به ورودی‌های مختلف فراهم می‌کنند. این تنظیم برای اطمینان از اینکه تحولات آموخته شده در طول فرآیند آموزش پایدار و کارآمد باقی می مانند بسیار مهم است.

برای مقداردهی اولیه توابع فعالسازی مناسب، هر تابع کوانتیزه می شود به طوری که پارامتر مقیاس $\omega s$ روی ۱ تنظیم می شود و تابع $spline(x)$ تقریباً صفر می شود. این استراتژی اولیه تضمین می‌کند که توابع فعال‌سازی اولیه ساده هستند و با حداقل سوگیری شروع می‌شوند و به شبکه اجازه می‌دهد تا با پیشرفت یادگیری، آنها را اصلاح کند. علاوه بر این، پارامتر بایاس $\omega b$ با استفاده از تکنیک اولیه سازی خاویر مقداردهی اولیه می شود. این روش مقادیر اولیه وزن ها را به گونه ای محاسبه می کند که واریانس هر دو

توابع فعال سازی و گرادیان های بین لایه ها حفظ شود. با حفظ این تعادل، مقداردهی اولیه Xavier به جلوگیری از مسائلی مانند مشکل گرادیان انفجاری یا ناپدید شدن کمک می‌کند، که می‌تواند فرآیند آموزش را با تقویت یا کاهش گرادیان‌ها در حین انتشار در لایه‌ها مختل کند. این مقداردهی اولیه دقیق به شبکه KAN اجازه می دهد تا با گرادیان های پایدار و همگرایی روان تر، به طور موثرتری آموزش ببینند.

در ادامه روند یادگیری، یکی دیگر از پارامتر های قابل یادگیری و مهم grid size می‌باشد.




شکل ۸: سمت چپ: نمادهای فعال‌سازی‌هایی که در شبکه جریان دارند. راست: یک تابع فعال‌سازی به‌عنوان B-Spline پارامتر می‌شود، که امکان جابجایی بین شبکه‌هایی با grid size بالا و پایین را فراهم می‌کند. [۱۵]

grid size تعداد نقاط استفاده شده در تابع B-spline است. اساساً، هر وزن در این مدل یک تابع تک بعدی قابل یادگیری است که به شکل یک spline شکل می گیرد و اندازه grid وضوح این spline را تعیین می کند.

در طول فرآیند آموزش، اندازه grid می‌تواند بر انعطاف‌پذیری و پیچیدگی عملکردهای فعال‌سازی تأثیر بگذارد. اندازه grid بزرگتر به توابع فعال سازی پیچیده تر و انعطاف پذیرتر منجر می شود، که به طور بالقوه می تواند الگوهای پیچیده تری را در داده‌ها ثبت کند. همچنین اندازه grid کوچکتر منجر به عملکردهای فعال سازی ساده تر می شود.

همانطور که مدل آموزش داده می شود، پارامترهای این spline ها (و در نتیجه توابع فعال سازی) برای به حداقل رساندن loss تنظیم می‌شوند. این فرآیند تنظیم شامل بهینه‌سازی پارمترهای توضیح داده شده من جمله مقادیر grid size است تا مدل به بهترین تناسب با داده‌های آموزشی برسد [۱۵].

مزیت کلیدی شبکه‌های *Kolmogorov-Arnold (KAN)* در توانایی آن‌ها برای تقریب یک تابع هدف با دقت دلخواه با استفاده از *splines* نهفته است. *Splines* توابع ریاضی هستند که می توانند با اصلاح شبکه ای که روی آن تعریف شده اند، مطابق با تابع هدف تنظیم شوند. همانطور که شبکه ریزدانه تر می شود، *spline* می تواند به طور فزاینده ای ساختار جزئیات تابع را به تصویر بکشد که منجر به تقریب های

دقیق تر می شـــود. این قابلیت به KAN ها اجازه می دهد تا به طور انعطاف پذیر با پیچیدگی داده هایی که مدل سازی می کنند سازگار شوند. در مقابل، پرسپترون‌های چند لایه سنتی (MLP) این مکانیسم داخلی را برای «ریزدانه‌ســـازی» ندارند. در حالی که افزایش عرض و عمق MLP ها می تولند منجر به بهبود عملکرد شود، مفهومی که به عنوان "قوانین مقیاس گذاری عصبی" شـناخته می شود، این بهبود با محدودیت هایی همراه اسـت. سـرعت بهبود عملکرد اغلب آهسـته اسـت و برای دسـتیابی به دسـتاوردهای قابل توجه نیاز به افزایش قابل توجهی در اندازه مدل دارد.

علاوه بر این، فرآیند افزایش مقیاس MLP از نظر محاسباتی گران است. هر اندازه مدل، چه از نظر عرض یا عمق بزرگتـر، باید به طور مستقل از ابتدا آموزش داده شود، که بـه منابع مـحاسباتی گسـترده نیاز دارد. در مقابل، KAN ها جـایگزین کارآمدتـر و مـقرون به صرفه تر هستند. هنگامی که یک KAN با تعداد معینی از پارامترها آموزش داده شد، مدل را می توان با اصلاح شبکه های *spline* آن (به طـور موثر افزایـش وضوح آن) بدون نیاز به آموزش مجدد مدل بزرگتر از ابتدا، مقیاس را افزایش داد. این توانایی برای گسـترش یک KAN از پیش آموزش دیده با تنظیم ساده دانه بندی خطوط، مدل را بسیار انعطاف پذیر و مقیاس پذیر می کند. بـا اجـازه دادن به پـالایـش مـداوم بدون نیـاز به بازآموزی، KAN ها مزایای قابل توجهی را از نظر کارایی محاسباتی و سازگاری ارائه مـی دهند و آنها را به یک جایگزین جذاب برای کارهایی تبدیل مـی کند که دقت و مقیاس پذیری ضروری است.

فـرآیند افزایـش طـول *grid* بدین صـورت اسـت که سـبب افزایـش وابستگی تابع فعال سازی قابل یـادگیری به تعداد بیشـتری از *spine* میشود. فرض کنید مـی‌خواهیم یک تابع ۱ بعدی $f$ را در یک ناحیه مـحدود $[a, b]$ با خـطوط $B$ از مـرتبـه $k$ تقریـب کـنیـم. ایـن *grid* بـا فـواصل $G_1$ تعدادی نـقـاط در $\{t_0 = a, t_1, t_2, \dots, t_{G_1} = b\}$ دارد که با افزایش سایز گرید، این نقاط به صورت $\{t_{-k}, \dots, t_{-1}, t_0, \dots, t_{G_1}, t_{G_1+1}, \dots, t_{G_1+k}\}$ تغییـر پیـدا میکنـد. در ایـن وضعیـت تعـداد نقاط تـابع پـایه *B-spine* به $G_1+k$ میـرسد. در ایـن صـورت نقـطه *i*ام از تـابع *B-spine* در نواحی $t_{-k+i}$ تا $t_{i+1}$ میـتواند مـقدار غیر صفـر داشـته باشـد. $f$ در شبـکه ای بـا *grid size* کـم بـر حسـب تـرکـیب خـطی ایـن تـوابع پـایـه *B-splines* بیان می شود:

$$f_{coarse}(x) = \sum_{i=0}^{G_1+k-1} c_i B_i(x)$$

در صورتی که *grid size* افزایش پیدا کند و برابر $G_2$ بشود شبکه زیردانه تشـکیل بدسـت می آید که ترکیب خطی توابع پایه *B-spine* آن به صورت زیر خواهد بود:

$$f_{fine}(x) = \sum_{i=0}^{G_2+k-1} c_i' B_i'(x)$$

پارامتر $c_i'$ در مقدار دهـی اولیه میتواند یک مـقداری را با توجه به پارامتر $c_i$ با کوچک کردن فاصله بین دو تابع $f_{fine}(x)$ و $fcoarse(x)$ به خود بگیرد.

$$\{c_j'\} = \underset{\{c_j'\}}{argmin} \underset{x\sim p(x)}{\mathbb{E}} \left( \sum_{j=0}^{G_2+k-1} c_j' B_j'(x) - \sum_{i=0}^{G_1+k-1} c_i B_i(x) \right)^2$$

رابطه ارائه شده میتواند توسط الگوریتم حداقل مربعات قابل پیاده سازی شود. مقداردهی و افزایش *grid size* در طی فرآینده یادگیری روی همه توابع *spine* موجود در شبکه KAN صورت میگیرد.

**شبکه های KAN کوچک تعمیم بهتری از ویژگی های یادگرفته شده را ارائه می دهند:** در برخی از موارد چه در زمینه دیتاست های معروف و چه دیتاست های ساختگی میتوان شبکه های کوچک تری را نیز معرفی کرد. جالب توجه است که در این گونه موارد این نوع شبکه ها می‌توانند *loss* کمتری را نسبت به شبکه های بزرگ تر بدست آورند. این ظرافت در انتخاب معماری های KAN را برجسته می کند. اگر ساختار مسئله را ندانیم، چگونه می‌توانیم حداقل شکل KAN را تعیین کنیم؟ در ادامه این بخش، روشی برای منظم سازی و هرس اتوماتیک معرفی خواهیم کرد.

همانطور که گفته شد، یکی از موارد مربوط به شروع آموزش این است که ما نمی دانیم چگونه شکل KAN را انتخاب کنیم که به بهترین وجه با ساختار یک مجموعه داده مطابقت داشته باشد. به عنوان مثال، اگر بدانیم که مجموعه داده از طریق فرمول نمادین $f(x, y) = exp(sin(\pi x)+y2$ تولید می شود، می دانیم که یک KAN[2, 1, 1] قادر به بیان این تابع است. با این حال، در عمل ما اطلاعات را از قبل نمی دانیم، بنابراین خوب است که رویکردهایی برای تعیین خودکار این شکل داشته باشیم. ایده این است که از یک KAN به اندازه کافی بزرگ شروع کنید و آن را با منظم سازی پراکنده و سپس هرس آموزش دهید. میتواند نشان داد که این KAN های هرس شده بسیار بیشتر از موارد هرس نشده قابل تفسیر هستند. برای اینکه KAN ها حداکثر قابل تفسیر باشند، چند تکنیک ساده سازیو نمونه ای از نحوه تعامل کاربران با KAN ها برای تفسیرپذیرتر کردن آنها در ادامه معرفی می کنیم.

**تکنیک های ساده سازی: ۱. اسپارس شدن:** برای MLP ها، تنظیم وزن های خطی L1 به نفع پراکندگی استفاده می شود. KAN ها می توانند این ایده سطح بالا را تطبیق دهند، اما به دو تغییر نیاز دارند. اول اینکه هیچ "وزن" خطی در KAN وجود ندارد. وزن های خطی با توابع فعال سازی قابل یادگیری جایگزین می شوند، بنابراین باید هنجار $L1$ این توابع فعال سازی را تعریف کنیم و دوم اینکه ما $L1$ را برای پراکندگی KANها کافی نمی‌دانیم. در عوض یک تنظیم آنتروپی اضافی لازم است. ما هنجار $L1$ یک تابع فعال‌سازی را به‌عنوان مقدار متوسط آن بر ورودی‌های $Np$ تعریف می‌کنیم:

$$|\phi|_1 \equiv \frac{1}{N_p} \sum_{s=1}^{N_p} |\phi(x^{(s)})|$$

سپس برای یک لایه KAN با $9$ ورودی و خروجی خروجی، هنجار $L1$ از $\Phi$ را به عنوان مجموع هنجارهای $L1$ همه توابع فعال سازی تعریف می کنیم:

$$|\Phi|_1 = \sum_{i=1}^{n_{in}} \sum_{j=1}^{n_{out}} |\phi_{i,j}|_1$$

علاوه بر این، آنتروپی $\Phi$ را بدین صورت تعریف می کنیم:

$$S(\Phi) \equiv -\sum_{i=1}^{n_{in}} \sum_{j=1}^{n_{out}} \frac{|\phi_{i,j}|_1}{|\Phi|_1} \log\left(\frac{|\phi_{i,j}|_1}{|\Phi|_1}\right)$$

با در نظر گرفتن اینکه *total loss* برابر مقدار کل *loss* یک شبکه است که از *pred loss* که مقدار خطای محاسبه به علاوه $L1$ بدست می آید. بدین ترتیب برای منظم‌سازی آنتروپی تمام لایه های KAN میتواند نوشت:

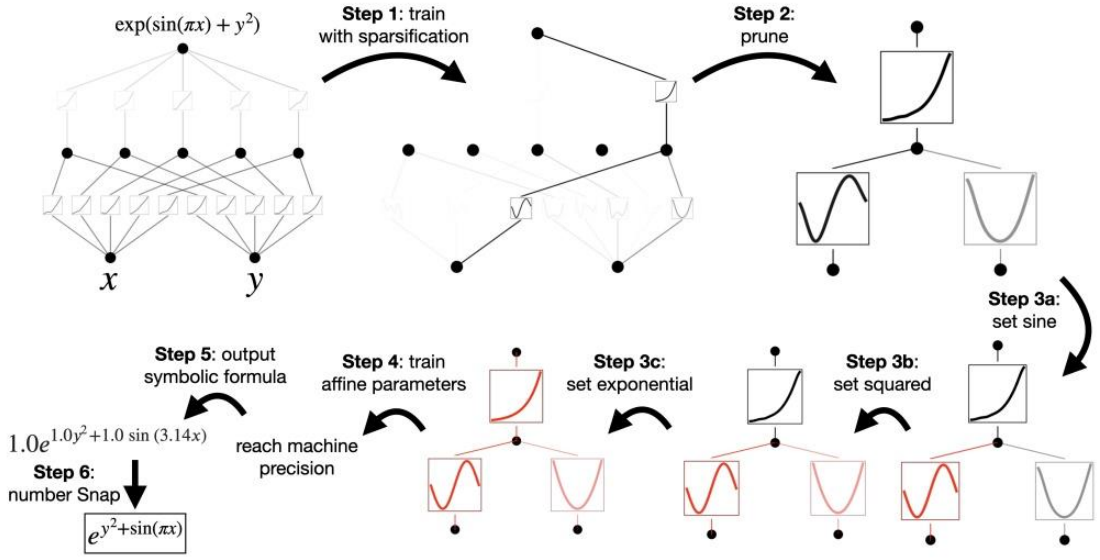
$$\ell_{total} = \ell_{pred} + \lambda\left(\mu_1 \sum_{l=0}^{L-1} |\Phi_l|_i + \mu_2 \sum_{l=0}^{L-1} S(\Phi_l)\right)$$

در این رابطه، $\mu 1$، $\mu 2$ قدرهای نسبی هستند که معمولاً روی $\mu 1 = \mu 2 = 1$ تنظیم می‌شوند و $\lambda$ بزرگی منظم‌سازی کلی را کنترل می‌کند.

**۲. تجسم:** وقتی یک KAN را تجسم می‌کنیم، برای دریافت حس بزرگی، شفافیت یک تابع فعال‌سازی $\phi_{l,i,j}$ را متناسب با $\tanh(\beta A_{l,i,j})$ قرار می‌دهیم که $\beta = 3$ است. از این رو، توابع با قدر کوچک محو شده اند تا به ما اجازه دهند روی موارد مهم تمرکز کنیم.

**۳. هرس:** پس از آموزش با پنالتی sparsification، ممکن است بخواهیم شبکه را به یک زیرشبکه کوچکتر تقسیم کنیم. ما KAN ها را در سطح گره (به جای سطح لبه) کوچک می کنیم. برای هر گره (مثلاً نورون $i$ در لایه $1$)، امتیاز ورودی و خروجی آن را به صورت زیر تعریف می کنیم:

**۴. نمادسازی:** در مواردی که گمان می‌کنیم برخی از توابع فعال‌سازی در واقع نمادین هستند (به عنوان مثال، *cos* یا *log*)، یک رابط برای تنظیم آن‌ها به عنوان یک فرم نمادین مشخص ارائه می‌کنیم، *fix_symbolic(l,i,j,f)* می‌تواند $(l, i, j)$ فعال سازی $f$ باشد. با این حال، ما نمی توانیم به سادگی تابع فعال سازی را به عنوان فرمول نمادین دقیق تنظیم کنیم، زیرا ورودی ها و خروجی های آن ممکن است دارای تغییرات و مقیاس بندی باشند. بنابراین، ما پیش فعال سازی $x$ و پس فعال سازی $y$ را از نمونه ها به دست می آوریم، و پارامترهای وابسته $(a، b، c، d)$ را به گونه ای برازش می کنیم که $y \approx cf(ax + b) + d$. برازش با جستجوی شبکه ای تکراری $a، b$ و رگرسیون خطی انجام می شود.




شکل ۹: نمونه ای از نحوه انجام رگرسیون نمادین با KAN [۱۵]

**یک مثال فرضی: چگونه انسان ها می توانند با KAN ها تعامل داشته باشند:**

در قسمت قبل، تعدادی از تکنیک های ساده سازی برای KAN ها را پیشنهاد کرده ایم. ما می‌توانیم این گزینه‌های ساده‌سازی را به عنوان دکمه‌هایی ببینیم که می‌توان روی آن کلیک کرد. کاربری که با این دکمه‌ها تعامل دارد، می‌تواند تصمیم بگیرد که روی دکمه بعدی کلیک کند تا KAN ها قابل تفسیرتر شوند. ما از مثال زیر استفاده می کنیم تا نشان دهیم که چگونه یک کاربر می تواند با یک KAN تعامل داشته باشد تا حداکثر نتایج قابل تفسیر را به دست آورد.

اجازه دهید دوباره تسک رگرسیون را در نظر بگیریم:

$$f(x, y) = \exp\left(\sin(\pi x) + y^2\right)$$

با توجه به نقاط داده، یک کاربر فرضی آلیس علاقه مند به کشف کردن است. از فرمول نمادین مراحل تعامل آلیس با KAN ها در زیر توضیح داده شده است:

مرحله ۱: آموزش با اسپاسفیکاسیون. شروع از یک *KAN* کاملاً متصل [2، 5، 1]، آموزش با منظم شدن پراکندگی می تواند آن را کاملاً پراکنده کند. ۴ نورون از ۵ نورون در لایه پنهان ظاهر می شوند. بی فایده است، بنابراین ما می خواهیم آنها را از بین ببریم.

مرحله ۲: هرس هرس خودکار برای دور انداختن تمام نورون‌های پنهان به جز آخرین نورون، یک KAN [2، 1، 1] باقی می‌ماند. به نظر می رسد توابع فعال سازی، توابع نمادین شناخته شده باشند.

مرحله ۳: تنظیم توابع نمادین. با فرض اینکه کاربر بتواند این فرمول های نمادین را از خیره شدن به نمودار KAN به درستی حدس بزند، می تواند تنظیم کند.

```
fix_symbolic(0,0,0,'sin')
fix_symbolic(0,1,0,'x^2')
fix_symbolic(1,0,0,'exp').
```

در صورتی کـه کاربر هیچ اطلاعی از دامـنه نداشته باشـد یا ایده ای نداشته باشد کـه این توابع فعال سـازی ممکن است کدام توابع نمادین باشند، ما یک تابع *suggest_symbolic* برای پیشـنهاد نـامزدهای نمادین ارائه می دهیم.

مرحله ۴: آمـوزش بیشـتر پـس از نمـاد تمام توابع فعال سازی در شبکه، تنها پارامترهای باقی مانده پارامتر *affine* هستند. ما به آموزش این پارامترهای وابسته ادامـه مـی‌دهیم، و وقتـی مـی‌بینیم که ضرر بـه دقـت ماشین کاهش می‌یابد، می‌دانیم که عبارت نمادین درسـت را پیدا کرده‌ایم.

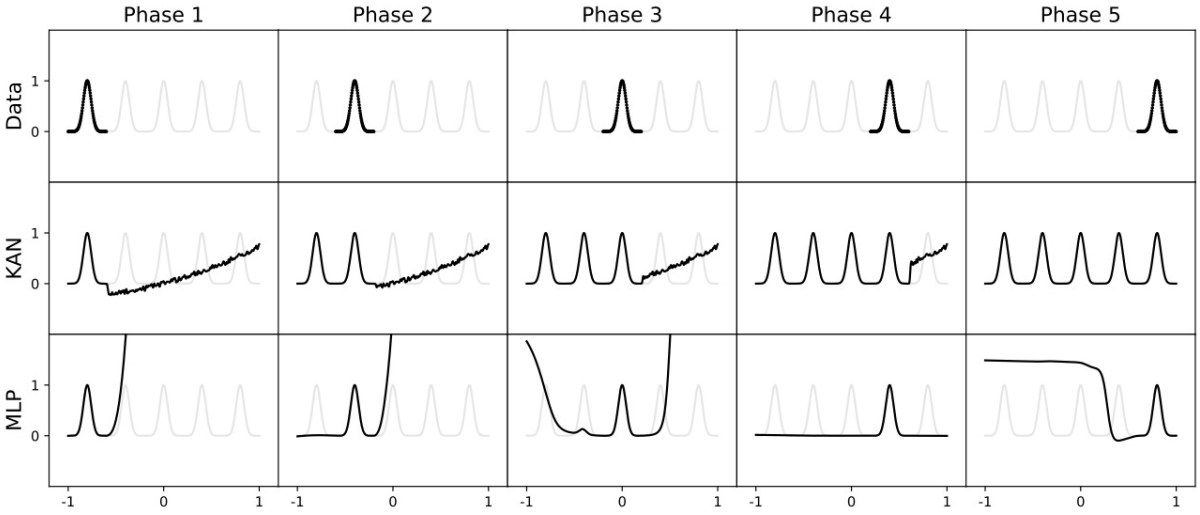
مرحله ۵: خروجی فرمول نمادین. *Sympy* برای مـحاسبه فـرمول نـمادین گـره خروجی اسـتفاده می شود. کاربر $1.0e^{1.0y2+1.0sin\ (3.14x)}$ را به دست می آورد که پاسخ واقعی است (ما فقط دو اعـشار را بـرای $\pi$ نمایش دادیم).

نکته: چرا رگرسیون نمادین ($SR$) نه؟ منطقی است که از رگرسـیون نمادین برای این مثال اسـتفاده کنیم. با این حال، روش های رگرسیون نمادین به طور کلی شـکننده هسـتند و اشکال زدایی آنها سـخت است. آن‌ها یا در نهایت یک موفقیت یا یک شکست را بدون خروجی نتایج متوسط قابل تفسیر برمی‌گردانند. در مـقابل، KAN ها جستجوی پیوسـته (با گرادیان نزول) را در فضای تابع انجام می دهند، بنابراین نتایج آنها پیوسـته تر و در نتیجه قوی تر است. علاوه بر این، به دلیل شـفافیت KAN ، کاربران نسـبت به SR کنترل بیشـتری بر روی KAN دارند. روشی که ما KAN ها را تجسم می کنیم مانند نمایش مغز KAN ها به کاربران است و کـاربران مـی توانند اشـکال زدایی را روی KAN ها انجام دهـند. این سـطح از کـنترل مـعمولاً برای SR در دسترس نیست.. به طور کلی، زمانی که تابع هدف نمادین نباشد، رگرسیون نمادین شکست خواهد خورد، اما KAN ها هنوز هم می توانند چیزی معنادار ارائه دهند. برای مثال، یادگیری یک تابع خاص (به عنوان مثال، یک تابع بسل) برای SR غیرممکن است مگر اینکه از قبل ارائه شده باشد، امـا KAN ها می تواننـد بـه هـر حال از *splines* برای تقریب عددی آن اسـتفاده کنند.

**یادگیری مستمر**: یکی از مهم‌ترین چالش‌ها در یادگیری ماشینی مدرن، موضوع فراموشی فاجعه‌بار است، که در آن یک مدل وقتی روی کارهای جدید آموزش می‌دهد، وظایفی که قبلاً آموخـته‌اند را فرامـوش می‌کند. در انسان ها وقتی مهارت جدیدی مانند جابجایـی از کـاری به کار دیگر یاد می گـیریم، کار قبلی را فراموش نمی کنیم. این به این دلیل است که مغز انسـان با ماژول های عملکردی گسسـته و محلی سـاخته شده است، جایی که یادگیری یک کار جدید تنها در مـناطق خاصی که مسـئول آن کار هسـتند مـنجر بـه سازماندهی مجدد ساختاری می شود. بقیه مغز بدون تأثیر باقی می ماند و اطلاعاتی که قبلاً آموخته شـده را حفظ می کند. متأسفانه، شبکه‌های عصبی سنتی، از جمله پرسپترون‌های چندلایه (MLP)، فاقد این مفهوم

محلی هستند. کل شبکه به طور معمول درگیر یادگیری است، و هنگامی که یک کار جدید معرفی می شود، پارامترهای جهانی را تغییر می دهد، که می تواند به طور ناخواسته اطلاعات آموخته شده برای کارهای قبلی را پاک کند. این رویکرد یادگیری جهانی احتمالاً علت فراموشی فاجعه‌بار است، زیرا تغییرات در کل شبکه بدون حفظ دانش آموخته‌شده قبلی منتشر می‌شوند.

در مقابل، شبکه‌های کولموگروف-آرنولد (KAN) به دلیل انعطاف‌پذیری محلی ذاتی خود، که به کاهش فراموشی فاجعه‌بار کمک می‌کند، مزیت مشخصی دارند. هسته اصلی این مزیت در محلی بودن ساختار مبتنی بر *spline* در KAN ها نهفته است. از آنجایی که اسپلاین ها ماهیتا محلی هستند، یک نمونه آموزشی جدید تنها بر ضرایب اسپلاین نزدیک تاثیر می گذارد و مناطق دوردست را دست نخورده باقی می گذارد. این یادگیری محلی به این معنی است که در حالی که اطلاعات جدید جذب و در مدل کدگذاری می شود، با مناطقی از شبکه که قبلاً دانش قبلی را یاد گرفته و ذخیره کرده اند تداخلی ایجاد نمی کند. این رویکرد مدولار و موضعی، روش یادگیری مغز انسان را تقلید می‌کند، جایی که تنها بخش‌های خاصی از مغز که مسئول مهارت جدید هستند، سازماندهی می‌شوند و مناطق دیگر دست نخورده باقی می‌مانند. در مقابل، MLP ها معمولاً به توابع فعال سازی جهانی مانند *ReLU*، *Tanh* یا *SiLU* متکی هستند. این فعال‌سازی‌ها تغییراتی را در کل شبکه اعمال می‌کنند، که می‌تواند منجر به تغییرات ناخواسته در مناطق دورتر شود و به طور موثر اطلاعات مهم ذخیره‌شده در طول کارهای قبلی را بازنویسی کند. توانایی KAN برای حفظ تغییرات محلی بدون ایجاد اختلال در کل شبکه، آن را به یک راه حل امیدوارکننده برای مشکل فراموشی شدید تبدیل می کند.

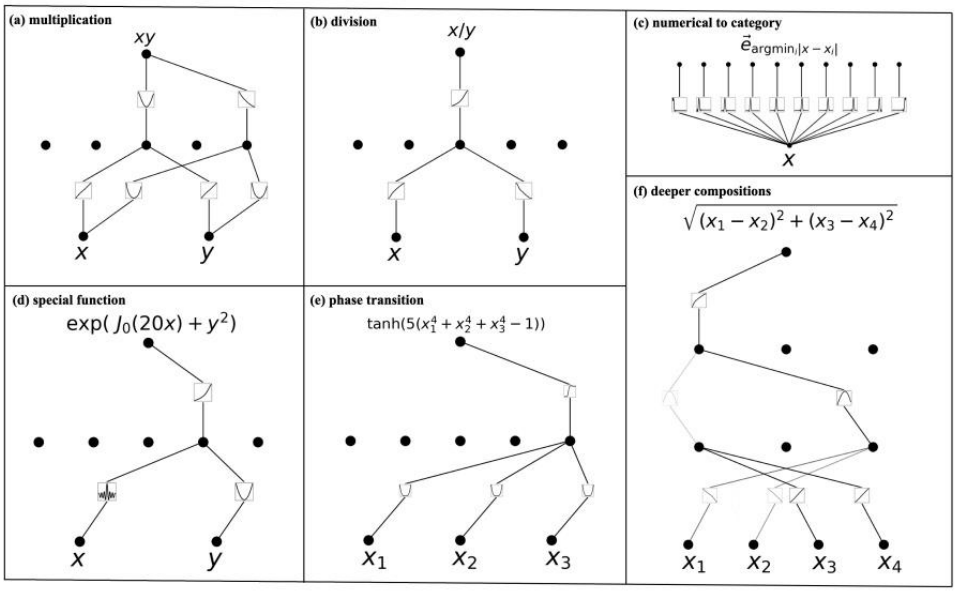



شکل ۱۰:

نمونه ای از مسئله یادگیری مستمر مجموعه داده یک کار رگرسیون ۱ بعدی با ۵ قله گاوسی (ردیف بالا).
داده‌های پیرامون هر پیک به‌طور متوالی (به جای همه یک‌باره) به KAN و MLP ارائه می‌شوند.
KAN ها (ردیف میانی) می توانند کاملاً از فراموشی شدید جلوگیری کنند، در حالی که MLP ها (ردیف پایین) فراموشی شدید را نشان می دهند. [۱۵]

**KAN ها قابل تفسیر هستند:** یکی از قانع‌کننده ترین مـزایای شبـکه‌هایKAN قابلیت تفسیر ذاتی آن‌ها است که آنها را نه تنها برای کارهای مصنوعی قدرتمند مـی‌کند، بلکه برای تحقیقات علمی در دنیای واقـعی نیز بسیار مناسـب اسـت. در حـالی که بسـیاری از شـبکه های عصبی، از جمله MLP های سـنتی، اغلب به عنوان مدل های "جعبه سیاه" به دلیل فرآیندهای تصمیم گیری پیچیده و مبهم مورد انتقاد قرار می گیرند، KAN هـا بـه دلـیل توانـایی خـود در ارائه بینـش در مورد روابـطی کـه یـاد مـی گیرند برجسـته هسـتند. ایـن تفسیرپذیری به محققان اجازه می‌دهد تا بررسی کنند که چگونه مدل به نتایج خـود مـی‌رسد و KAN را به ابزاری امیدوارکننده برای تحقیقات علمی تبـدیل مـی‌کند. در مطالعـات ما، KAN هـا ظـرفیت کشـف مجدد روابط بسیار غیر پیش پا افتاده در نظریه گره را نشان داده اند - شاخه ای انتـزاعی از ریاضـیات که به مطالعه گره ها و خواص آنها مربوط می شود. علاوه بر این، KAN ها بـرای شـناسایی مـرزهای انتقال فاز در فیزیک مـاده مـتراکم استفاده شـده اند، و تـوانایی آنـها را برای مـقابله با پدیده های پیچیده و دنیای واقعی با دقت نشان می دهند.

KAN ها به دلیل ترکیبی از دقت و شفافیت، پتانسیل ارائه یک مدل اساسی برای اکتشاف عـلمی مـبتنی بر هوش مصنوعی را ارائه می دهند. ساختار آنها، که مـبتنی بر توابع تک مـتغیره قابل یادگیری و نمایـش های مبتنی بر *spline* اسـت، نـمای روشـنی از نحوه تبـدیل ورودی ها به خروجی ارائه می دهد. این در تضاد با بسیاری از مدل‌های یادگیری عمیق است که در آن‌ها تفسیر فرآیند تصمیم‌گیری دشوار است. توانایی تفسیر روابط آموخته شده در تحقیقات علمی بسیار مهم اسـت، جـایی که درک مکانیسـم هـای اسـاسـی به اندازه دستیابی به دقت بالا مهم است. با ارائه پیـش‌بینی‌هـای دقـیق و بینش‌هـای قابل تفسیر،KAN ها مـی‌توانند شکاف بین یادگیری ماشین و اکتشافات علمی را پر کنند و آنـها را به عنوان ابزاری کلـیدی در آینده هـوش مصنوعی + علم قرار دهند.




شکل ۱۱: KAN ها برای کارهای نمادین ساده قابل تفسیر هستند [۱۵]

## ۲-۲ شبکه عصبی گرافی کولموگروف-آرنولد: GraphKAN

با توضیح نحوه کارکرد شبکه عصبی KAN، اکنون به نحوه استفاده از آن در شبکه عصبی GraphKAN به عنوان یک مدل مشتق شده از آن می‌پردازیم. شبکه عصبی GraphKAN یک تجمیع اطلاعات قدرتمندی از داده‌های گراف مانند فراهم می‌کند. با توجه به این توانایی representation یا بازنمایی بهبود یافته، از این مدل در دسته بندی رئوس گراف (Node Classification) یا دسته بندی گراف ( Graph Classification) استفاده شود.

شبکه های عصبی مبتنی بر نمودار توانایی منحصر به فردی برای پردازش و تفسیر داده های ساختار یافته با استفاده از چارچوبی به نام ارسال پیام دارند. این چارچوب شبکه را قادر می‌سازد تا نه تنها ویژگی‌های گره‌ها (یا رئوس) منفرد، بلکه روابط و اتصالات بین آنها را نیز ثبت کند. به طور خاص، ارسال پیام به شبکه اجازه می دهد تا اطلاعاتی مانند نحوه اتصال راس ها، ویژگی های راس هدف، ویژگی های رئوس همسایه و ویژگی های یال هایی که راس هدف را به همسایگانش پیوند می دهد، جمع آوری و ترکیب کند. این اطلاعات از طریق شبکه به روشی ساختاریافته منتقل می شود و به آن امکان می دهد وابستگی های پیچیده را در داده های نمودار یاد بگیرد.

در شبکه GraphKAN، این چارچوب ارسال پیام در هر لایه استفاده می‌شود و توانایی شبکه برای مدل‌سازی تعاملات پیچیده موجود در ساختارهای گراف را افزایش می‌دهد. با استفاده از این رویکرد، GraphKAN می‌تواند به طور موثر ویژگی‌های محلی و جهانی گراف را بیاموزد و آن را قادر می‌سازد تا وظایف مربوط به داده‌های گراف را به خوبی انجام دهد. نقش این شبکه عصبی در توانمندسازی شبکه برای مدیریت ماهیت غنی و چند بعدی اطلاعات مبتنی بر گراف بسیار مهم است. چارچوب تبادل پیغام یا Message Passing شامل دو مرحله زیر می باشد:

۱) **تجمع و دریافت اطلاعات** از همسایه های گره هدف: در این مرحله از تابع پیغام استفاده میشود:

$$m_v^{t+1} = \sum_{\omega \in N(v)} M^t(h_v^t, h_\omega^t, e_{v\omega}^t)$$

مطابق رابطه ارائه شده، $m_v^{t+1}$ بردار اطلاعات دریافت شده توسط یک گره از گراف برای لایه بعدی $t+1$ است. $M^t$ تابع پیغام است. $h_v^t$ و $h_\omega^t$ به ترتیب بردار ویژگی های گره هدف و همسایه آن می‌باشد. $e_{v\omega}^t$ نیز بردار ویژگی های یال بین گره هدف و همسایه آن می‌باشد. در GraphKAN تابع پیغام همانند GCN بوده و مطابق رابطه زیر می‌باشد:

$$[\deg(v)\deg(\omega)]^{-1/2} A_{v\omega} h_\omega^t$$

$A_{v\omega}$ یک درایه از ماتریس مجاورت می‌باشد برای گراف دارای بردار ویژگی برای یال‌ها، این درایه از ماتریس

مجاورت شامل همان بردار ویژگی است در غیر این صورت برابر یک است؛ به معنای وجود یال بین گره هدف و همسایه. عبارت $[\deg(v)\deg(\omega)]^{-1/2}$ به جهت نرمال سازی بکار رفته است زیرا بدون آن برای گره هایی با تعداد همسایه های بالا خروجی تابع پیغام بزرگ تر از گره هایی با تعداد همسایه های کمتر خواهد بود. بدین جهت از این نرمال سازی برای جلوگیری از دخیل شدن این مشکل استفاده می‌شود [۱۶].

۲) **استخراج** بازنمایی گره گراف: پس از مرحله تبادل پیغام، که در آن اطلاعات از گره های همسایه جمع می‌شود (با استفاده از تابع $M^t$)، تابع بروز رسانی گره این اطلاعات جمع شده را می دریافت کرده و آن را با ویژگی های فعلی گره ترکیب می‌کند تا ویژگی های لازم را برای گره بعدی تولید کند.

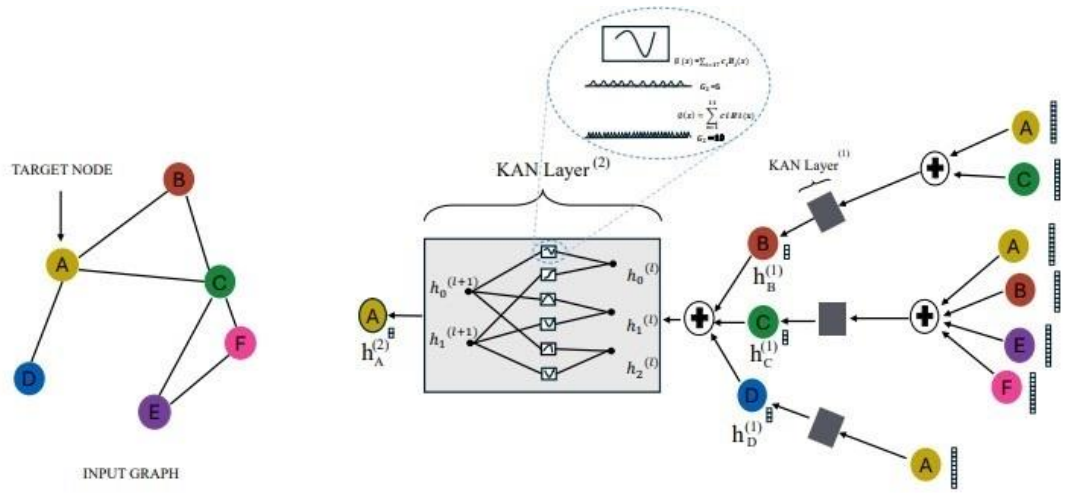
رابطه تابع بروز رسانی به صورت زیر است:

$$h_{\omega}^{t+1} = U^t(h_v^t, m_v^{t+1}) = KAN^t(h_v^t, m_v^{t+1}) = \Phi^t(h_v^t, m_v^{t+1})$$

مطابق رابطه ارائه شده، تابع بروز رسانی در حقیقت یک لایه از شبکه عصبی KAN می‌باشد.

وجود این چارچوب برای هر لایه از این شبکه، اجازه می دهد تا نمایش گره ها به تدریج در لایه ها اصلاح شود و الگوها و روابط پیچیده تری را در گراف ثبت کند. عملکرد لایه KAN در مرحله دوم این چارچوب بسیار مهم است زیرا اطلاعات تازه جمع‌آوری شده از گره های همسایه را با ویژگی های گره موجود یکپارچه می‌کند، در نتیجه مدل را قادر می‌سازد تا توانایی ایجاد بازنمایی های مؤثرتر برای ورودی های داده شده به آن بیاموزد.

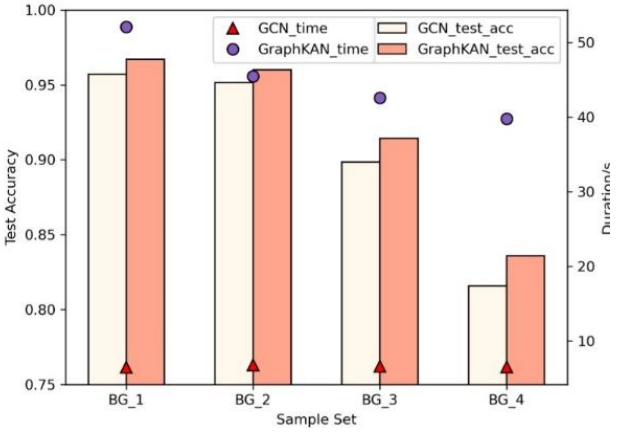
برای اطمینان از آموزش پایدار و موثر شبکه GraphKAN، نرمال سازی لایه (LayerNorm) بین لایه های این شبکه انجام می‌شود. LayerNorm با نرمال سازی ورودی ها به هر لایه کمک می کند که مسائلی مانند انفجار یا ناپدید شدن گرادیان ها را کاهش می دهد و منجر به یادگیری سازگارتر و روان تر می شود. این تکنیک به این شبکه اجازه می دهد تا به طور کارآمدتر همگرا شود و عملکرد آن را بهبود شود به خصوص هنگام وجود چندین لایه در معماری های عمیق مانند GraphKAN [۱۷].




شکل ۱۲: معماری و عملکرد شبکه عصبی GraphKAN
بدون در نظر گرفتن نرمال سازی های درون لایه ای و بین لایه ای [۱۸]

**تأیید عملکرد این شبکه عصبی**: پیش از پرداختن به روش کار اصلی پروژه خوب است به مراحل آزمایش و تایید عملکرد مدل GraphKAN اشاره کرد و کارایی آن را سنجید. یک کار طبقه بندی گره برای اعتبار سنجی برتری GraphKAN ساخته شده است. این از یک وظیفه تشخیص الگو برای سیگنال های یک بعدی که از یک پمپ جریان محوری جمع آوری می شود نشات می گیرد [۳]. یک روش ساخت گراف خاص در طراحی شده است که رابطه بین نمونه ها را نشان می دهد. در این بخش، نمودارهای ساخته شده به نام گراف‌های پایه (BG) برای طبقه‌بندی گره‌ها برای تایید اثر بهبود GraphKAN استفاده می‌شوند. با توجه به تفاوت تعداد نمونه‌های برچسب‌دار، چهار نمودار همانطور که در جدول نشان داده شده است، ساختیم. ۱. گره های برچسب زده شده را می توان برای آموزش مدل و اعتبارسنجی مدل استفاده کرد و گره های تست در این چهار نمودار یکسان هستند. دو مدل، یعنی GraphKAN و GCN به طور جداگانه برای پردازش BG ها انجام می شوند. فراپارامترهای آن‌ها همگی روی یک مقدار تنظیم شده‌اند، همانطور که در جدول، نشان داده شده است. در این مطالعه، ما از زمان‌بندی نرخ یادگیری CosineAnnealingLR در PyTorch برای تنظیم پویا نرخ یادگیری استفاده کردیم. ما حداکثر تعداد دوره‌ها را روی ۲۰۰ تنظیم کردیم و حداقل نرخ یادگیری را روی e-41 محدود کردیم. هدف این پیکربندی تنظیم نرخ یادگیری از طریق آنیل کسینوس برای متعادل کردن سرعت همگرایی و عملکرد مدل در طول آموزش است. تنظیمات فوق برای هر دو مدل معتبر است.

به طور تصادفی ۲۰ درصد از گره‌های برچسب‌گذاری شده را برای اعتبارسنجی مدل انتخاب میشود، و دقت اعتبارسنجی به عنوان معیاری برای تعیین هم‌گرایی مدل عمل میشود. ۷۰۰ گره بدون برچسب برای آزمایش مدل استفاده می شود. ده آزمایش شامل آموزش مدل، اعتبارسنجی و آزمایش انجام شد، و میانگین دقت آزمون و مدت زمان با استفاده از نمودارهای ورودی مختلف در شکل ۱ نشان داده شده است. به زمان بیشتر محاسبات KAN نسبت داده می شود. با این حال، می توان مشاهده کرد که دقت تست GraphKAN نسبت به GCN، به ویژه در BG_3 و BG_4، برتر است. اگرچه زمان مصرف به طور قابل توجهی افزایش یافته است، بهبود دقت حتی ارزشمندتر است. علاوه بر این، زمان مصرف در یک محدوده قابل کنترل، کمتر از یک دقیقه باقی می‌ماند. در عین حال، ما همچنین متوجه شدیم که اثر بهبود GraphKAN زمانی که گراف ورودی دارای گره‌های برچسب‌دار کمتری مانند BG_3 و BG_4 باشد، قابل توجه‌تر است. این موضوع به خوبی نشان میدهد که GraphKAN دارای اهمیت بالقوه برای وظایف طبقه بندی few-shot است.




شکل ۱۳: مقایسه دقت تست و مصرف زمان شبکه های عصبی GCN و GraphKAN [۱۷]

# فصل ۳

# روش پیشنهادی

در این فصل به توضیح دقیق معماری مدل DTANet جهت پیشبینی ارتباط دارو-پروتئین هدف می‌پردازیم. این مدل برگرفته از معماری GraphDTA و با اعمال شبکه عصبی GraphKAN در آن ایجاد شده است. در این مدل ارتباط دارو-هدف به شکل یک مسئله رگرسیون در نظر گرفته شده است بدین صورت که خروجی نهایی این مدل یک اندازه‌گیری پیوسته از این ارتباط می‌باشد.

## ۳-۱ تشکیل بازنمایی دارو

در حوزه شیمی محاسباتی و کشف دارو، نمایش دقیق ترکیبات شیمیایی برای پردازش و تجزیه و تحلیل بسیار مهم است. یک سیستم به طور گسترده برای این منظور SMILES یا سیستم ورودی خط ورودی مولکولی ساده شده است که یک قالب استاندارد برای رمزگذاری ساختار مولکول های شیمیایی به عنوان یک رشته خطی متن است. این سیستم نمایشی فشرده و قابل خواندن برای انسان از مولکول ها ارائه می دهد و ذخیره، به اشتراک گذاری و پردازش اطلاعات شیمیایی در قالب های دیجیتال را آسان تر می کند. SMILES به دلیل سادگی و کارایی آن در نمایش ساختارهای پیچیده ترکیبات شیمیایی به نحوی که کامپیوترها بتوانند به راحتی از عهده آن برآیند، به سنگ بنای شیمی‌فورماتیک تبدیل شده است.

در SMILES ، هر اتم درون یک مولکول با نماد اتمی استاندارد آن از جدول تناوبی نشان داده می شود. برای مثال، "C" مخفف کربن، "O" برای اکسیژن و "N" برای نیتروژن است. پیوندهای بین اتم ها، اعم از منفرد، دوتایی یا سه گانه، می توانند به صراحت با استفاده از نویسه هایی مانند "-"، "="، و "#" بیان شوند، یا می توان آنها را به طور ضمنی بر اساس زمینه اتم های اطراف درک کرد. شاخه‌ها و ساختارهای حلقه‌ای که در شیمی آلی رایج هستند، با نشانه‌های خاصی مدیریت می‌شوند. نقاط انشعاب در ساختار مولکولی با استفاده از پرانتز نشان داده می‌شوند که به رشته SMILES اجازه می‌دهد از یک مسیر خطی ساده منحرف شود، در حالی که بسته‌های حلقه با اعداد نشان داده می‌شوند، که نشان می‌دهد کجا ساختار به خودش حلقه می‌زند. به عنوان مثال، "C1CCCCC1" نشان دهنده سیکلوهگزان، یک ساختار حلقه شش کربنی است.

زیبایی SMILES در تطبیق پذیری آن نهفته است. این می تواند طیف گسترده ای از ساختارهای شیمیایی، از مولکول های ساده مانند آب ("O") تا ترکیبات بسیار پیچیده را رمزگذاری کند، در حالی که همچنان

یک نحو ساده را حفظ می کند. علاوه بر این، SMILES می تواند مولکول های آلی و غیر آلی را نشان دهد و آن را به یک سیستم جهانی تبدیل می کند. این سادگی به آن اجازه می دهد تا به راحتی در یادگیری ماشین و سایر مدل های محاسباتی ادغام شود. ابزارها می توانند به سرعت رشته های SMILES را به نمودارهای مولکولی ترجمه کنند، جایی که اتم ها به گره ها و پیوندها به لبه تبدیل می شوند، و این سیستم را برای استفاده در شبکه های عصبی مبتنی بر نمودار مانند GraphKAN ایده آل می کند. با این حال، ماهیت فشرده SMILES نیز چالش هایی را ایجاد می کند، زیرا یک مولکول می تواند با چندین رشته SMILES مختلف، بسته به ترتیبی که در آن اتم ها نوشته می شوند، نمایش داده شود. به همین دلیل است که قالب ها و الگوریتم های استاندارد شده، مانند SMILES متعارف، اغلب برای اطمینان از سازگاری در نمایش های مختلف استفاده می شوند.

به طور کلی، سیستم SMILES ابزاری قدرتمند و انعطاف‌پذیر برای نمایش ساختارهای شیمیایی برای کارهای محاسباتی فراهم می‌کند و به محققان این امکان را می‌دهد تا به طور موثر با مجموعه داده‌های بزرگی از ترکیبات شیمیایی کار کنند. این ابزار به یک ابزار ضروری در خطوط لوله کشف دارو تبدیل شده است که پردازش سریع اطلاعات شیمیایی را برای مدل‌های یادگیری ماشینی، شبیه‌سازی اتصال و سایر روش‌های تحلیلی امکان‌پذیر می‌سازد. [۱۹].

برای به دست آوردن یک نمایش معنادار از ساختار شیمیایی یک دارو، این فرآیند شامل ایجاد یک بردار است که ویژگی های اساسی ترکیب را در بر می گیرد. برای تولید چنین نمایش هایی می توان از روش های مختلفی استفاده کرد، SMILES یک نمایش خطی و مبتنی بر متن از مولکول را ارائه می دهد و ترکیب اتمی و اتصال پیوند آن را به تصویر می کشد. با این حال، هنگامی که این رمزگذاری خطی مستقیماً به عنوان یک بردار استفاده می شود، اطلاعات ساختاری مهمی را از دست می دهد، به ویژه اینکه چگونه اتم های درون مولکول به هم متصل می شوند. این محدودیت می تواند مانع از اثربخشی هر مدل یادگیری ماشینی شود که سعی در یادگیری خواص دارو دارد، زیرا روابط فضایی بین اتم ها به خوبی شناسایی نشده است. در نتیجه، تکیه صرفاً به SMILES برای بازنمایی دارو ممکن است منجر به یادگیری کمتر از حد مطلوب و عملکرد پیش‌بینی شود.

برای افزایش عملکرد مدل‌های محاسباتی در کشف دارو، تبدیل نمایش SMILES به یک قالب ساختاریافته‌تر و آموزنده‌تر، مانند نمودار مولکولی، ضروری است. یک نمودار مولکولی با نشان دادن اتم ها به عنوان گره و پیوندها به عنوان لبه بین این گره ها، جزئیات پیچیده ساختار شیمیایی را حفظ می کند. این رویکرد مبتنی بر نمودار تضمین می‌کند که مدل نه تنها اتم‌ها و ویژگی‌های آنها را به تصویر می‌کشد، بلکه روابط و اتصال بین آنها را نیز به تصویر می‌کشد. در این نمایش، هر گره مربوط به یک اتم است و مجموعه ای از ویژگی ها را می توان با هر گره مرتبط کرد تا توصیف غنی تری از ساختار شیمیایی ارائه دهد.

در رویکرد خود، مجموعه‌ای از ویژگی‌های اتمی را با الهام از مدل DeepChem برای توصیف هر گره در نمودار مولکولی اتخاذ می‌کنیم. هر اتم به عنوان یک بردار ویژگی باینری چند بعدی نشان داده می شود که پنج قطعه کلیدی اطلاعات را منتقل می کند: نماد اتمی (مانند C برای کربن یا O برای اکسیژن)، تعداد اتم

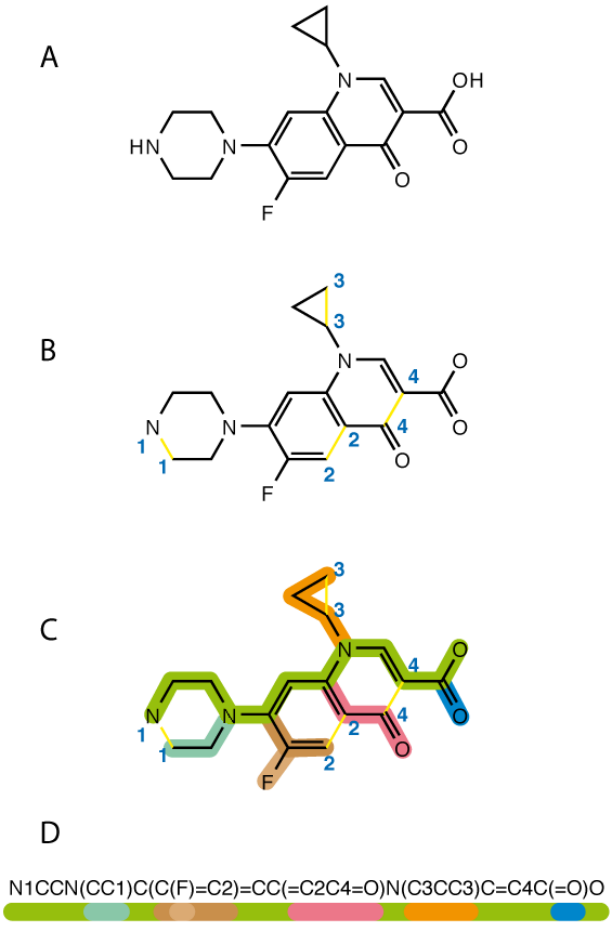
های مجاور (که به توصیف ساختار پیوند کمک می کند)، عدد. از اتم های هیدروژن مجاور، مقدار ضمنی اتم (که شامل اطلاعاتی مانند پیکربندی بار و پیوند است)، و اینکه آیا اتم بخشی از یک ساختار معطر است یا خیر. معطر بودن یک ویژگی مهم در شیمی است که اغلب با پایداری و انواع خاصی از واکنش پذیری مرتبط است و آن را به یک ویژگی مهم در نمایش مولکولی تبدیل می کند.

برای تسهیل تبدیل از رشته SMILES به گراف مولکولی و استخراج ویژگی های اتمی، از نرم افزار شیمیفورماتیک منبع باز RDKit استفاده می کنیم. RDKit ابزاری پرکاربرد است که می تواند رشته های SMILES را تفسیر کرده و آنها را به نمودارهای مولکولی تبدیل کند. فرآیند شناسایی پیوندها، اتم‌ها و زیرساخت‌ها و همچنین محاسبه خواص مهم اتمی را خودکار می‌کند. با استفاده از RDKit، می‌توانیم به طور مؤثر یک نمودار مولکولی ایجاد کنیم که در آن هر اتم با مجموعه ویژگی‌های دقیق حاشیه‌نویسی می‌شود و اطمینان حاصل می‌کند که نمایش اطلاعات ساختاری غنی لازم برای پیش‌بینی دقیق خواص دارو را حفظ می‌کند.

هنگامی که نموداری که ساختار مولکولی دارو را نشان می‌دهد، تشکیل شد، می‌توان آن را به یک شبکه عصبی وارد کرد تا یک نمایش برداری استخراج شود که ویژگی‌های شیمیایی ضروری دارو را در بر می‌گیرد. این ناقل به عنوان "نماینده" دارو عمل می کند و برای کارهای پایین دستی مانند پیش بینی تداخلات دارو-هدف یا سایر خواص دارویی بسیار مهم است. فرآیند یادگیری این نمایش توسط ساختار نمودار مولکولی هدایت می‌شود، جایی که شبکه هر دو ویژگی‌های اتمی فردی و روابط بین آنها را ثبت می‌کند.

شبکه عصبی مسئول یادگیری این بازنمایی داروها در رویکرد ما GraphKAN است که در فصل قبل معرفی شد. GraphKAN به طور خاص برای مدیریت داده های ساختار یافته طراحی شده است و آن را برای نمایش داروها در سطح مولکولی مناسب می کند. با پردازش نمودار مولکولی دارو از طریق یادگیری عمیق، GraphKAN یک نمایش در سطح نمودار را می آموزد که اطلاعات ساختاری و شیمیایی کل مولکول را رمزگذاری می کند. سپس این نمایش آموخته شده را می توان برای کارهای مختلف پیش بینی، از جمله تعیین اینکه چگونه یک دارو ممکن است با پروتئین هدف تعامل داشته باشد یا ارزیابی اثربخشی بالقوه آن در تنظیمات درمانی، استفاده شود.

GraphKAN با استفاده از چارچوب ارسال پیام عمل می کند و به آن اجازه می دهد اطلاعات را از ساختارهای محلی و جهانی در نمودار مولکولی جمع آوری کند. هر لایه از شبکه نمایش را اصلاح می‌کند و روابط پیچیده‌تر بین اتم‌ها و اتصالات آنها را به تصویر می‌کشد. خروجی نهایی شبکه یک نمایش برداری است که ویژگی‌های کلیدی ساختار شیمیایی دارو را خلاصه می‌کند و پایه‌ای قوی برای تجزیه و تحلیل و پیش‌بینی‌های بیشتر فراهم می‌کند.




شکل ۱۴: نمونه ای از الگوریتم تولید SMILES [۲۳].

## ۳-۲ تشکیل بازنمایی پروتئین هدف

قبل از هر چیز، مهم است که اذعان کنیم که پیچیدگی ساختاری پروتئین ها بسیار بیشتر از ترکیبات شیمیایی مانند داروها است. در حالی که ابزارهایی مانند SMILES برای رمزگذاری ساختار شیمیایی داروها در یک رشته متن ساده کار می کنند، این روش برای پروتئین ها به دلیل ساختار بسیار پیچیده تر و بزرگتر آنها مناسب نیست. پروتئین‌ها از زنجیره‌های بلندی از اسیدهای آمینه تشکیل شده‌اند که به روش‌های بسیار خاصی تا می‌شوند و با هم تعامل دارند تا شکل‌های سه‌بعدی خود را ایجاد کنند. این تفاوت های ساختاری نقش مهمی در عملکردهای بیولوژیکی آن ها ایفا می کند. در نتیجه، رمزگذاری ساختار یک پروتئین به تکنیک‌های پیچیده‌تری نسبت به آنچه برای مولکول‌های ساده‌تر مانند داروها در دسترس است، نیاز دارد.

چالش در نمایش پروتئین ها به این دلیل است که آنها از اسیدهای آمینه متعددی تشکیل شده اند که هر کدام خواص منحصر به فرد خود را دارند و ترتیب و ترتیب مکانی این اسیدهای آمینه عملکرد پروتئین را مشخص می کند. برای شروع کدگذاری ساختار پروتئین، اولین قدم کاهش آن به اجزای اصلی

آن - اسیدهای آمینه است. هر پروتئین را می توان به عنوان یک توالی طولانی از این اسیدهای آمینه در نظر گرفت، و این توالی پایه و اساس هر نمایش محاسباتی پروتئین را تشکیل می دهد. با این حال، به جای استفاده از سیستمی مانند SMILES برای ایجاد یک کد خطی، از پایگاه های داده و تکنیک های رمزگذاری استفاده می کنیم که به طور خاص برای پروتئین ها طراحی شده اند.

یکی از این منابع پایگاه داده UniProt است که به طور گسترده برای نمایش توالی های پروتئین در قالبی استفاده می شود که هم از نظر محاسباتی قابل دسترسی باشد و هم از نظر بیولوژیکی آموزنده. UniProt توالی اسید آمینه پروتئین ها را با استفاده از یک فرمت استاندارد ارائه می دهد که در آن هر اسید آمینه با یک کاراکتر ASCII مشخص می شود. به عنوان مثال، ۲۰ اسید آمینه استاندارد با نویسه هایی مانند "A" برای آلانین، "C" برای سیستئین و غیره نشان داده می شوند. این فرمت ساختار پیچیده و سه بعدی یک پروتئین را به دنباله ای تک بعدی ساده می کند که اطلاعات ضروری در مورد ساختار اولیه پروتئین را حفظ می کند. با تبدیل پروتئین‌ها به این توالی‌های اسید آمینه معادل، می‌توانیم تکنیک‌های محاسباتی را برای تحلیل و مدل‌سازی رفتار آن‌ها به کار ببریم، اگرچه ممکن است روش‌های بیشتری برای توضیح پیچیدگی کامل آن‌ها مانند ساختارهای ثانویه و ثالثه همچنان مورد نیاز باشد.

استفاده از کاراکترهای ASCII برای نشان دادن آمینو اسیدها یک گام کلیدی در امکان تجزیه و تحلیل محاسباتی پروتئین ها است، اما این تنها آغاز فرآیند است. هنگامی که توالی به دست آمد، تغییر شکل‌های بیشتر و تکنیک‌های استخراج ویژگی برای به تصویر کشیدن جنبه‌های ظریف‌تر ساختار و عملکرد پروتئین اعمال می‌شود. این به داده‌ها اجازه می‌دهد تا به مدل‌های یادگیری ماشینی وارد شوند، که سپس می‌توانند تعاملات، عملکردها و مکان‌های بالقوه اتصال دارو را بر اساس توالی به تنهایی پیش‌بینی کنند. پس از این، هر کاراکتر از دنباله معادل پروتئین هدف به یک عدد طبیعی نگاشت می‌شود تا در ادامه جهت تشکیل بازنمایی مورد نظر استفاده شود. به جهت فرآیند یادگیری بهتر مدل، دنباله اعداد به یک یا چندین دنباله با طول ثابت ۱۰۰۰ تبدیل میشوند یعنی در صورتی که دنباله اولیه طول بیشتری داشت، برش خورده و به دو دنباله کوتاه تر تبدیل میشود. در صورتی که دنباله اولیه کوتاهتر باشد، با مقادیر صفر پر می شود. این دنباله های اعداد طبیعی به عنوان ورودی لایه های embedding استفاده می‌شوند تا یک بردار ۱۲۸ بعدی را برگردانند.

در مرحله بعد، یک شبکه عصبی کانولوشنی (CNN) با سه لایه کانولوشن ۱ بعدی برای پردازش بردار ۱۲۸ بعدی ورودی استفاده می شود. هر لایه کانولوشن در CNN برای یادگیری ویژگی های پیچیده و انتزاعی داده های ورودی طراحی شده است. اولین لایه کانولوشنال الگوهای اساسی را ثبت می‌کند. همانطور که داده ها از لایه های کانولوشنی بعدی عبور می‌کنند، این الگوها ترکیب و تبدیل می شوند و به شبکه اجازه می‌دهد تا روابط پیچیده تر و ویژگی های سطح بالاتر را شناسایی کند. این فرآیند استخراج ویژگی سلسله مراتبی، CNN را قادر می‌سازد تا درک عمیقی از ساختار و الگوهای اساسی موجود در بردار ورودی ایجاد کند. در نهایت، یک لایه max pooling اعمال می‌شود تا ویژگی های آموخته شده را به یک نمایش فشرده‌تر متراکم کند. خروجی این شبکه عصبی، توالی پروتئین هدف مورد نظر است.

## ۳-۳ پیش بینی میزان ارتباط با استفاده از بازنمایی ترکیبی

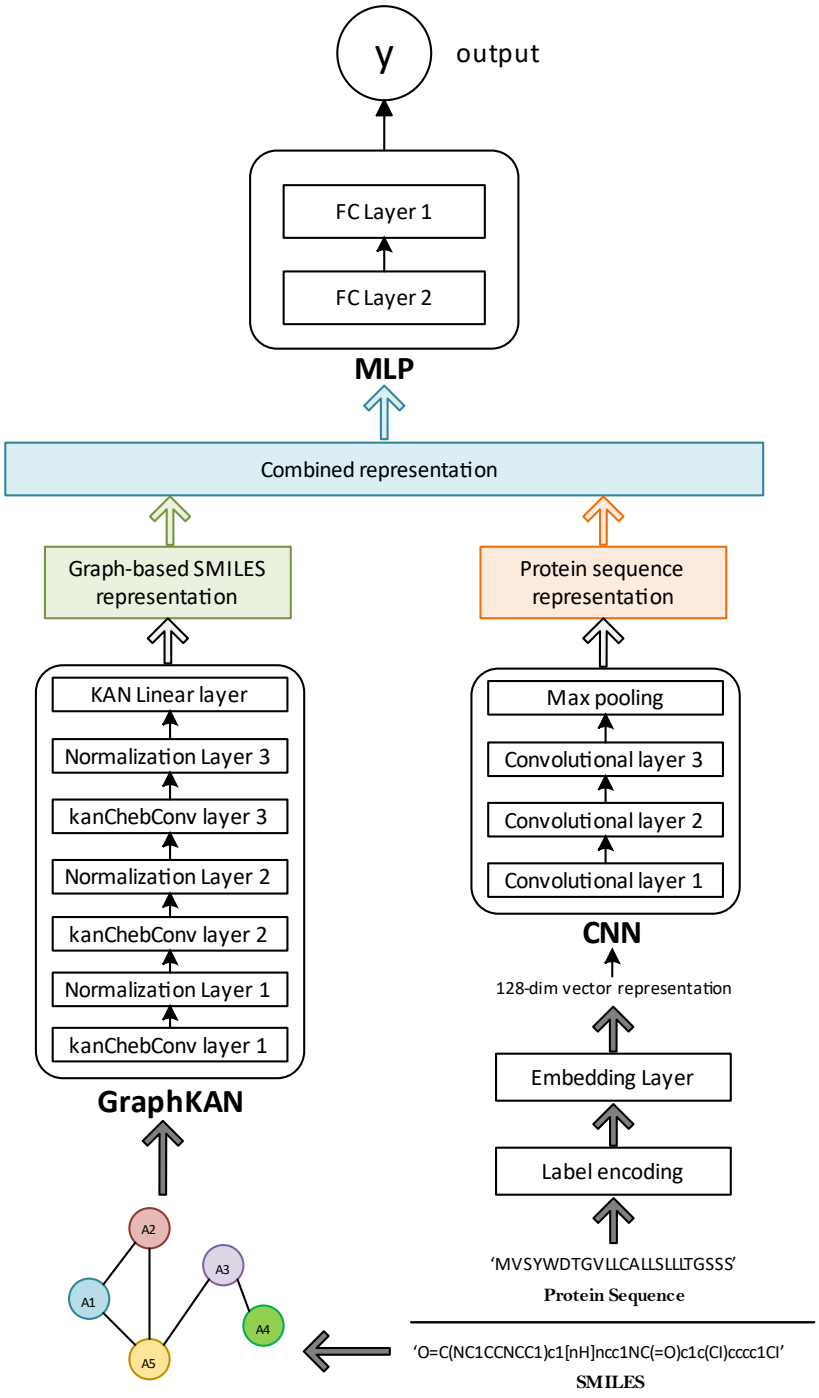
هنگامی که بردارهای نمایش برای دارو و پروتئین هدف به دست آمد، گام مهم بعدی ترکیب این دو نمایش برای به دست آوردن ویژگی های کلیدی هر دو موجود در یک فرم یکپارچه است. وکتور دارو اطلاعات ضروری در مورد ساختار مولکولی آن را رمزگذاری می کند، در حالی که وکتور پروتئین هدف حاوی جزئیاتی در مورد توالی اسید آمینه آن و سایر ویژگی های ساختاری بالقوه است. با ترکیب این دو بردار، ما یک نمایش واحد و جامع ایجاد می کنیم که مهم ترین ویژگی های آموخته شده از دارو و پروتئین را در بر می گیرد.

این نمایش ترکیبی بسیار مهم است زیرا دیدی جامع از تعامل بین دارو و پروتئین ارائه می دهد. فرآیند ترکیب بردارها به مدل این امکان را می دهد که نه تنها ویژگی های جدا شده دارو و پروتئین، بلکه روابط بین آنها را نیز تجزیه و تحلیل کند. این بردار ادغام شده به عنوان ورودی برای مرحله بعدی خط لوله محاسباتی عمل می کند.

شبکه عصبی MLP این نمایش ترکیبی را برای پیش‌بینی نهایی پردازش می‌کند. با عبور بردار از لایه های متعدد، MLP روابط آموخته شده را اصلاح می کند و یک پیش بینی به دست می دهد که تعامل دارو-هدف را کمی می کند. این پیش‌بینی معمولاً به‌عنوان یک مقدار عددی در یک بازه زمانی مشخص نشان داده می‌شود، که می‌تواند با نتایج مختلفی مانند میل اتصال یا قدرت تعامل مطابقت داشته باشد. عدد خروجی توسط MLP روشی ساده برای ارزیابی احتمال اتصال یا تعامل دارو با پروتئین هدف، که برای کشف و توسعه دارو بسیار مهم است، فراهم می‌کند.

## ۴-۳ جمع بندی معماری کلی DTANet

شکل (۱۵) معماری کلی این مدل را به همراه شبکه های پایه ای بکار رفته در آن را نشان میدهد. در این مدل، دو نمایش جداگانه - توالی پروتئین و نمودار مولکولی دارو - به صورت موازی پردازش شده و سپس یکپارچه می شوند تا یک مدل جامع از تعامل دارو-هدف را تشکیل دهند. توالی پروتئین، پس از عبور از چندین لایه کانولوشن، یک نمایش برداری شده ایجاد می کند که ویژگی های بیولوژیکی کلیدی را به تصویر می کشد. به طور همزمان، ساختار مولکولی دارو از طریق یک رویکرد مبتنی بر نمودار با استفاده از GraphKAN، که روابط بین اتم‌ها را در مولکول ثبت می‌کند، کدگذاری می‌شود. این دو مجموعه ویژگی در یک نمایش یکپارچه ترکیب می شوند و اطلاعات هر دو حوزه مولکولی و پروتئین را ادغام می کنند. این بردار ویژگی ترکیبی سپس به یک پرسپترون چندلایه (MLP) منتقل می‌شود، که در نهایت قدرت برهم‌کنش را پیش‌بینی می‌کند (در شکل با "Y" مشخص شده است). MLP داده‌های ادغام شده را از طریق لایه‌های کاملاً متصل پردازش می‌کند تا پیش‌بینی میل هدف دارو را ارائه دهد، و DTANet را قادر می‌سازد تا داده‌های مبتنی بر توالی و گراف را به طور موثر برای بهبود عملکرد پیش‌بینی‌کننده مهار کند.




شکل ۱۵: معماری مدل DTANet

# فصل ۴

# پیاده‌سازی پروژه

در ایـن فصل به ارائه توضیحاتی در مورد ساختار کد پروژه می پردازیم و سپس به صورت کلی روند اجرایی را با ارائه توضیحاتی در مورد فایل هـای دخیل در بدسـت آوردن مـدل آمـوزش دیده شـده و نتـایج نـشان میـدهیم.

## ۴-۱ ساختار کلی کد پروژه

سـورس کـد ایـن پروژه به چندین مؤلفه کلیدی تقسیم می شود که هر کدام نقش خاصی را در فرآیند کلی یادگیری ایفا می کنند:

۱. تعریف مـدل در فایل model.py: این فایل معماری DTANetرا تعریف می کند که ماژول هـای مـختلف شبکه عصبی را ترکیب می کند. DTANetدر هسته خود از GraphKAN استفاده می کند که از لایـه های kanChebConv و KANLinear تشکیل شده است. این لایه‌های مبتنی بر گراف با یک CNN یـک بعدی و یک MLPتکمیل می‌شوند و این مدل را قادر می‌سازد تا اطلاعات سطح نمودار و سطح توالی را از داده‌هـای ورودی دریافت کند.

۲. فرآیند یادگیری بدون اعتبارسنجی (validation) در فایل learn.py: این اسکریپت فرآیند یادگیری اصلی مدل را مدیریت می‌کند و چرخه‌های آموزشی را بدون احتساب مرحله اعتبارسـنجی اجرا مـی‌کند. در درجه اول بر آموزش مدل با استفاده از یک مـجموعه داده از پیش تعریف شـده و بهینه سازی پارامترها بر اسـاس یک تابع ضرر متمرکز است.

۳. فرآیند یادگیری با اعتبارسنجی (validation) در فایل learn_with_validation.py: مشابه learn.py، این اسکریپت شامل یک مرحله اعتبار سنجی اضافی در طـول فـرآیند آمـوزش اسـت. ایـن مـرحله برای ارزیابی

عملکرد مدل در طول آموزش برای جلوگیری از تطبیق بیش از حد و اطمینان از تعمیم به داده‌های دیده نشده ضروری است.

۴. utils.py: این فایل حاوی توابع و کلاس‌های کاربردی ضروری برای پشتیبانی از پروژه است، مانند TestbedDataset، که مسئول بارگیری و مدیریت مجموعه داده‌ها (مانند مجموعه داده‌های Davis و Kiba) و معیارهای مختلف عملکرد مورد استفاده برای ارزیابی دقت و عملکرد مدل است.

۵. ایجاد و پیش پردازش داده ها در فایل create_data.py: این فایل تمام مراحل پیش پردازش مورد نیاز قبل از وارد کردن داده ها به مدل را مدیریت می کند. این داده‌های ورودی خام را به قالبی سازگار با PyTorch تبدیل می‌کند و اطمینان می‌دهد که مدل می‌تواند داده‌ها را در طول آموزش به طور موثر پردازش کند. این پیش پردازش اغلب شامل مدیریت ساختارهای نمودار مولکولی داروها و پروتئین ها می شود.

۶. مجموعه داده ها در دایرکتوری data: این پوشه شامل مجموعه داده‌های دیویس و کیبا است که معمولاً از معیارهایی در کارهای پیش‌بینی تعامل دارو-هدف استفاده می‌شوند. این مجموعه داده ها متشکل از تعاملات شناخته شده بین داروها و پروتئین ها هستند و برای آموزش و ارزیابی مدل DTANet استفاده می شوند.

۷. نتایج نهایی در دایرکتوری final results: این دایرکتوری پارامترهای آموخته شده مدل از دوره های آموزشی قبلی را همراه با بهترین نتایج بدست آمده در مجموعه داده های مربوطه ذخیره می‌کند. این به عنوان یک مخزن برای نقاط بازرسی مدل و خلاصه عملکرد عمل می کند.

## ۴-۲ روند اجرایی کد پروژه

اسکریپت model.py به عنوان پایه ای برای تعریف معماری شبکه عصبی مورد استفاده در آزمایش عمل می کند. این فایل طرح اصلی مدل را محصور می‌کند و جزئیات نحوه جریان داده از طریق آن را نشان می‌دهد. در این مورد، مدل می تواند پیاده سازی یک شبکه Kolmogorov-Arnold (KAN) یا GraphKAN باشد، همانطور که قبلا ذکر شد. این مدل ها به عنوان جایگزینی برای رویکردهای سنتی تر مانند پرسپترون های چند لایه (MLPs) عمل می کنند. این معماری به گونه‌ای طراحی شده است که ورودی‌های با ابعاد بالقوه بالا را مدیریت کند و داده‌ها را به گونه‌ای پردازش کند که ویژگی‌های مرتبط را برای کار در دست استخراج کند.

کلاس درون model.py لایه ها و توابع فعال سازی را که مدل را می سازند تعریف می کند. هر لایه داده های ورودی را قبل از ارسال به لایه بعدی تبدیل می کند و نمایش های انتزاعی فزاینده ای از ورودی

ایجاد می‌کند. اگر مدل شامل داده‌های گراف باشد، احتمالاً توجه ویژه‌ای به مکانیسم‌های ارسال پیام داده می‌شود، جایی که هر گره در نمودار می‌تواند اطلاعات را با همسایگان خود مبادله کند. هنگامی که معماری تعریف شد، تابع عبور به جلو برای توصیف نحوه حرکت داده ها در شبکه در طول استنتاج یا آموزش پیاده سازی می شود. این طراحی به انعطاف‌پذیری و مدولار بودن اجازه می‌دهد و تغییرات آسانی را در معماری با تکامل آزمایش ممکن می‌سازد.

forward pass بسیار مهم است زیرا توضیح می دهد که چگونه هر لایه تبدیل خود را به داده های ورودی اعمال می کند، از ویژگی های خام تا پیش بینی های نهایی. نتیجه این پاس معمولاً یک پیش‌بینی است، مانند برچسب طبقه‌بندی یا خروجی رگرسیون، که در مراحل بعدی آموزش با مقادیر حقیقت زمین مقایسه می‌شود.

اسکریپت learn_with_validation.py کل آزمایش را با مدیریت آموزش و اعتبارسنجی مدل تعریف شده در model.py هماهنگ می‌کند. این اسکریپت جایی است که اکثر منطق آزمایش در آن قرار دارد. هنگامی که مدل اولیه شد، اسکریپت به بارگذاری مجموعه داده ادامه می‌دهد، و اغلب آن را به مجموعه‌های آموزشی، اعتبارسنجی و آزمایش تقسیم می‌کند. این تقسیم به ارزیابی عملکرد مدل در طول فرآیند آموزش اجازه می‌دهد و تضمین می‌کند که فراپارامترها را می‌توان بر اساس معیارهای اعتبارسنجی تنظیم کرد، نه فقط نتایج آزمایش نهایی.

فرآیند آموزش تکراری است و وزن مدل در چندین دوره به روز می شود. در طول هر دوره، داده های آموزشی از طریق مدل منتقل می شود و خروجی های پیش بینی شده با مقادیر واقعی با استفاده از یک تابع ضرر مقایسه می شوند. تفاوت بین مقادیر پیش‌بینی‌شده و واقعی (از دست دادن) برای تنظیم وزن‌های مدل از طریق انتشار پس‌انداز و یک بهینه‌ساز مانند Adam یا SGD استفاده می‌شود. این چرخه برای تعداد دوره های از پیش تعیین شده یا تا زمانی که عملکرد اعتبارسنجی به آستانه مطلوب برسد ادامه می یابد.

علاوه بر آموزش، اسکریپت دارای یک حلقه اعتبار سنجی است. در فواصل زمانی منظم، مدل بر روی مجموعه داده اعتبارسنجی ارزیابی می‌شود و به آزمایشگر اجازه می‌دهد تا میزان تعمیم مدل به داده‌های دیده نشده را ردیابی کند. این برای تشخیص بیش از حد برازش بسیار مهم است، جایی که مدل در داده های آموزشی عملکرد خوبی دارد اما در داده های جدید ضعیف است. معیارهایی مانند accuracy، percision، recall یا از دست دادن برای هر دو مجموعه آموزشی و اعتبارسنجی ثبت می‌شوند و تصویر واضحی از عملکرد مدل ارائه می‌دهند.

در نهایت، اسکریپت احتمالاً بهترین مدل را در طول آموزش ذخیره می‌کند (بر اساس عملکرد اعتبارسنجی)، و اطمینان حاصل می‌کند که بهترین وزن‌ها را می‌توان برای آزمایش یا آزمایش‌های آینده

استفاده کرد. به این ترتیب، فرآیند آموزش هم کارآمد و هم تطبیقی است و بازخوردی از حلقه اعتبارسنجی برای تنظیم دقیق مدل را در بر می‌گیرد.

ترکیب model.py و learn_with_validation.py یک راه‌اندازی آزمایشی مدولار و جامع را تضمین می‌کند. معماری مدل کاملاً از فرآیند آموزش جدا شده است که امکان انعطاف پذیری در طراحی انواع مختلف شبکه ها و پروتکل های آموزشی را فراهم می کند. مکانیسم اعتبار سنجی تعبیه شده در اسکریپت تضمین می کند که مدل به خوبی تعمیم می یابد و فقط داده های آموزشی را حفظ نمی‌کند. به طور کلی، این راه‌اندازی آزمایشی برای بهبود مکرر عملکرد مدل و انطباق فرآیند آموزشی آن بر اساس بازخورد مستمر از مجموعه اعتبارسنجی طراحی شده است و از یک گردش کار آموزشی قوی و قابل اطمینان اطمینان می‌دهد.

# فصل ۵

# نتایج آزمایش‌ها

در این فصل به معرفی دو مجموعه معیاری می‌پردازیم که جهت آموزش و سنجش میزان عملکرد مدل استفاده می‌شوند سپس نتایج مدل را طبق متریک های ارزیابی که معرفی خواهند شد برای هر دو مجموعه داده نشان می‌دهیم و پس از آن به مقایسه این نتایج با مدل های قبلی می‌پردازیم. در انتها با ارائه پیشنهاداتی برای کار های آینده، فصل را به پایان می‌بریم.

## ۵-۱ معرفی مجموعه داده های معیار

به جهت مقایسه مدل معرفی شده با مدل های دیگر مانند DeepDTA و WideDTA از دو مجموعه داده زیر استفاده می‌کنیم:

- اولین مجموعه داده Davis نام دارد که شامل ۷۲ دارو و ۴۴۲ پروتئین هدف می‌باشد. میزان ارتباط بین تمامی این داروها و پروتئین های هدف در این مجموعه داده موجود است و به عنوان ثابت $K_d$ عنوان شده است. بازه آن نیز از ۵.۰ تا ۱۰.۸ متغیر می‌باشد [۲۱].
- دومین مجموعه داده Kiba نام دارد که شامل میزان ارتباط اندازه‌گیری شده بین ۲۱۱۶ دارو و ۲۲۹ پروتئین هدف تحت عنوان "امتیاز Kiba" می‌باشد. بازه این امتیاز بین ۰.۰ تا ۱۷.۲ میباشد [۲۲].

## ۵-۲ مقایسه نتایج مدل معرفی شده با دیگر مدل ها

برای اینکه مقایسه بین مدل ها تا حد امکان منصفانه باشد، از همان مجموعه داده های آموزشی و آزمایشی مقاله مربوط به GraphDTA استفاده می‌کنیم و همچنین از متریک های ارزیابی یکسان نیز استفاده می‌کنیم: میانگین مربع خطا (MSE، کوچکتر بهتر) و شاخص تطابق (CI، بزرگتر بهتر).

شـاخص تـطابق (CI) معیـاری اسـت کـه نشـان مـی‌دهد چقدر پیش بینی های مدل با رتبه بندی واقعـی نقـاط داده مطابقـت دارد. ایـن شاخص به ویژه در مورد ارتباط دارو-هدف مفید است. CI با محاسبه نسبـت تمـام جـفت نمونه هایی که به درستی مرتب شده اند، محاسبه می شود، مطابق رابطه ارائه شده، اگر N جفت امتیاز پیش‌بینی‌شده مانند $p_i$ و $p_j$ وجـود داشته باشد که مقادیر درست متناظرشان $y_i$ و $y_j$ باشد، CI به صورت زیر محاسبه میشود:

$$CI = \frac{1}{N}\sum I[(y_i - y_j) - (p_i - p_j) > 0]$$

تـابع I[·] در صـورتـی کـه رابـطه داخل آن صدق کند یک برمیگرداند و در غیر این صورت صفر برمیگرداند.

Mean Squared Error (MSE) مـیانگـین اختـلاف مـجذور بیـن مقادیر پیش بینی شده و مقادیر واقـعی را انـدازه گیـری مـی‌کند. ایـن یـک معیار رایج برای وظایف رگرسیون است، که نشان می‌دهد چقدر پیش‌بینی‌ها به مـقادیر واقـعی نزدیـک هسـتند، MSE پایـیـن‌تـر نـشان‌دهنده دقت بهتر مدل است. MSE به صورت زیر محاسبه می شود:

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - p_i)^2$$

میـزان عمـلکرد هـمه مـدل هـایی کـه برای مقایسه انتخاب شده اند، در جدول (۲) و (۳) برای دو مجموعه داده Davis و Kiba ارائه شده است. هـایپـرپارامترهای مورد استفاده برای DTANet نیز در جدول (۱) خلاصه شـده‌اند. ایـن هـایپـرپـارامترها بهینه نشده اند ولی بر اساس ترکیبی از هایپرپارامترهای معرفی شده در دو مقاله GraphKAN و GraphDTA تنظیم شـده اند.

مـطابق جدول (۲) و (۳) همانطور که مشـاهده مـی‌شود، شبکه DTANet توانسته است بدون انجام بهینه سازی روی هایپرپارامترهایش و در تلاش اول، از بیشتر مدل های Baseline و دو شبکه عصبی معرفی شده در مقاله GraphDTA عملکرد بهتری را در نتایج حاصل از متریک های CI و MSE نشان بدهد.

جدول (۱): هایپرپارامترهای DTANet

| Hyper-parameters | Setting |
|---|---|
| Learning rate | 0.0005 |
| Batch size | 512 |
| Optimizer | Adam |
| Dropout rate | 0.2 |
| kanChebConv layers | 3 |
| KAN Linear layers | 1 |

جدول (۲): مقایسه میزان عملکرد مدل ها بر روی مجموعه داده Davis

| Method | Protein rep. | Compound rep. | CI | MSE |
|---|---|---|---|---|
| Baseline models | | | | |
| KronRSL | Smith-Waterman | Pubchem-Sim | 0.871 | 0.379 |
| SimBoost | Smith-Waterman | Pubchem-Sim | 0.872 | 0.282 |
| DeepDTA | 1D | 1D | 0.878 | 0.261 |
| WideDTA | 1D + PDM | 1D + LMCS | 0.886 | 0.262 |
| GraphDTA models | | | | |
| GCN | 1D | Graph | 0.880 | 0.254 |
| GAT_GCN | 1D | Graph | 0.881 | 0.245 |
| GAT | 1D | Graph | 0.892 | 0.232 |
| GIN | 1D | Graph | 0.893 | 0.229 |
| DTANet | | | | |
| GraphKAN | 1D | Graph | **0.884** | **0.238** |

جدول (۳): مقایسه میزان عملکرد مدل ها بر روی مجموعه داده Kiba

| Method | Protein rep. | Compound rep. | CI | MSE |
|---|---|---|---|---|
| Baseline models | | | | |
| KronRSL | Smith-Waterman | Pubchem-Sim | 0.782 | 0.441 |
| SimBoost | Smith-Waterman | Pubchem-Sim | 0.836 | 0.222 |
| DeepDTA | 1D | 1D | 0.854 | 0.204 |
| WideDTA | 1D + PDM | 1D + LMCS | 0.863 | 0.194 |
| GraphDTA models | | | | |
| GCN | 1D | Graph | 0.866 | 0.179 |
| GAT_GCN | 1D | Graph | 0.882 | 0.147 |
| GAT | 1D | Graph | 0.889 | 0.139 |
| GIN | 1D | Graph | 0.891 | 0.139 |
| DTANet | | | | |
| GraphKAN | 1D | Graph | **0.884** | **0.145** |

# فصل ۶

# نتیجه گیری و ارائه پیشنهادها برای کارهای آینده

این گزارش پروژه موفقیت پتانسیل یادگیری عمیق را در پرداختن به چالش استفاده مجدد از دارو با مدل‌سازی روابط دارو-هدف نشان می‌دهد. مدل پیشنهادی، DTANet ، از معماری شبکه های عصبی برای پردازش و پیش بینی این روابط استفاده می کند و راه حلی خودکار و کارآمد در زمینه کشف دارو ارائه می دهد. استفاده از DTANet ظرفیت روش های یادگیری عمیق مبتنی بر متن را برای انجام وظایف پیچیده که به طور سنتی توسط مدل های مبتنی بر گراف به آنها پرداخته می شود برجسته می کند.

معماری DTANet به طور کامل مورد بررسی قرار گرفت، با تمرکز بر نحوه ادغام ویژگی های مبتنی بر متن برای گرفتن الگوهای اساسی در تعاملات دارو-هدف. طراحی و فرآیند یادگیری مدل تضمین می کند که می تواند به خوبی در مجموعه داده های مختلف تعمیم یابد و آن را به ابزاری همه کاره در تحقیقات دارویی تبدیل می کند. توانایی آن در ترکیب داده های پیچیده در حالی که یک ردپای محاسباتی قابل مدیریت را حفظ می کند، DTANet را به جایگزینی جذاب برای مدل های با منابع فشرده تر تبدیل می کند.

نتایج مقایسه ای نشان می دهد که DTANet با مدل های پیشرفته ای مانند GAT در مدل GraphDTA قابل رقابت است. علیرغم تفاوت در رویکرد، DTANet در معیارهای ارزیابی کلیدی عملکرد قابل مقایسه، اگر نگوییم برتر، به دست می آورد. این نشان می‌دهد که شبکه‌های عصبی مبتنی بر متن می‌توانند به اندازه رویکردهای مبتنی بر نمودار در گرفتن روابط دارو-هدف مؤثر باشند و جهت جدیدی را برای تحقیقات آینده در استفاده مجدد دارو ارائه دهند.

به منظور افزایش بیشتر عملکرد مدل‌های پیش‌بینی رابطه دارو-هدف، چندین جهت امیدوارکننده را می‌توان بررسی کرد. اول، ساخت یک نمودار مولکولی برای پروتئین هدف می تواند پیشرفت های قابل توجهی را ارائه دهد. در حالی که این رویکرد به دلیل چالش های موجود اجتناب شده است، پرداختن به این موانع می تواند پتانسیل جدیدی را باز کند. پروتئین ها موجودات بسیار پیچیده ای با ساختارهای سه بعدی و برهمکنش های دینامیکی هستند و تبدیل این ساختارها به یک نمودار دقیق که اطلاعات مکانی و شیمیایی را حفظ می کند، دشوار است. علاوه بر این، پروتئین ها انواع مختلفی از برهمکنش ها، مانند

پیوندهای آبگریز، یونی، و کووالانسی دارند که به چالش ایجاد یک نمودار مولکولی جامع می افزاید. با این حال، موفقیت در غلبه بر این مسائل می تواند به طور قابل توجهی توانایی مدل را برای پیش بینی تداخلات دارو-هدف افزایش دهد. ابزارهای محاسباتی پیشرفته، مانند شبیه‌سازی‌های دینامیک مولکولی و مدل‌های یادگیری عمیق مبتنی بر نمودار که می‌توانند داده‌های مکانی را پردازش کنند، ممکن است در تحقق این امر نقش داشته باشند.

جهت امیدوارکننده دیگر برای کار آینده، بهینه‌سازی بیشتر معماری و فراپارامترهای مدل‌ها، هم در DTANet و هم در مدل‌های مرتبط مانند GraphDTA است. در این پروژه، فراپارامترها به صورت تجربی تعیین شدند، اما یک رویکرد سیستماتیک تر با استفاده از تکنیک هایی مانند جستجو شبکه ای، جستجوی تصادفی، یا روش های پیشرفته تر مانند بهینه سازی بیزی می تواند نتایج بهتری به همراه داشته باشد.
منابع محاسباتی محدود و پیچیدگی بالای این مدل‌ها دلایلی بود که این موضوع در این پروژه بیشتر مورد بررسی قرار نگرفت. با منابع بیشتر، تکنیک‌هایی مانند زمان‌بندی نرخ یادگیری، مقدار اولیه وزن بهتر، یا توابع مختلف فعال‌سازی را می‌توان بررسی کرد. بهینه‌سازی معماری مدل - احتمالاً با ترکیب تکنیک‌های پیشرفته مانند اتصالات باقی‌مانده، مکانیسم‌های توجه یا لایه‌های مختلف ادغام - همچنین می‌تواند به عملکرد قوی‌تری منجر شود.

کاوش در معماری‌های شبکه عصبی جایگزین، به‌ویژه آن‌هایی که از شبکه Kolmogorov-Arnold (KAN) الهام گرفته شده‌اند، می‌تواند راه جدیدی برای افزایش دقت پیش‌بینی ارائه کند. در این پروژه از معماری های سنتی مانند CNN و MLP برای اجزای خاصی از مدل استفاده شد. با این حال، با توجه به نتایج چشمگیر نشان داده شده توسط KAN در گرفتن روابط غیرخطی پیچیده، استفاده از آن یا انواع آن به جای CNN و MLP می تواند مثمر ثمر باشد. شالوده نظری KAN به آن اجازه می دهد تا طیف گسترده ای از عملکردها را تقریب کند و به طور بالقوه آن را با پیچیدگی تعاملات دارو-هدف سازگارتر می کند. تحقیقات بیشتر می‌تواند شامل توسعه معماری‌های جدید مبتنی بر KAN یا انطباق معماری‌های موجود برای تطابق بهتر با حوزه استفاده مجدد از دارو باشد. علاوه بر این، ترکیب KAN با شبکه‌های عصبی گراف یا مکانیسم‌های مبتنی بر توجه می‌تواند مرزهای مدل‌سازی پیش‌بینی‌کننده را در این زمینه بیشتر کند.

علاوه بر جهت‌هایی که قبلاً ذکر شد، چندین راه دیگر برای کار آینده در پیش‌بینی میل ترکیبی دارو-هدف می‌تواند مورد بررسی قرار گیرد. یکی از زمینه‌های امیدوارکننده، ترکیب داده‌های چندوجهی است که می‌تواند قدرت پیش‌بینی مدل‌ها را افزایش دهد. در این پروژه ابتدا از داده های توالی پروتئین ها و ویژگی های مولکولی داروها استفاده شد. با این حال، داده‌های اضافی مانند برهم‌کنش‌های پروتئین-پروتئین (PPI)، نمایه‌های بیان ژن، یا سایر داده‌های omics (به عنوان مثال، رونوشت‌شناسی یا پروتئومیکس) می‌توانند اطلاعات زمینه‌ای غنی‌تری ارائه دهند. ادغام این انواع داده‌های متنوع از طریق معماری‌های یادگیری عمیق چندوجهی، مانند مدل‌های ترکیبی که لایه‌های کانولوشنال را برای داده‌های دنباله‌ای با شبکه‌های عصبی نموداری برای داده‌های ساختاری ترکیب می‌کنند، می‌تواند به بهبود دقت و تعمیم مدل کمک کند.

یکی دیگر از زمینه های بالقوه برای بهبود، استفاده از یادگیری انتقالی است. با توجه به دشواری جمع‌آوری مجموعه داده‌های بزرگ و با کیفیت بالا برای وظایف خاص وابسته به هدف دارو، یادگیری انتقال می‌تواند مدل‌ها را قادر سازد تا از دانش آموخته‌شده از وظایف یا مجموعه داده‌های مرتبط استفاده کنند. پیش‌آموزش در پایگاه‌های اطلاعاتی بیوشیمیایی در مقیاس بزرگ، مانند PubChem یا ChEMBL، و به دنبال آن تنظیم دقیق روی جفت‌های خاص دارو-هدف، می‌تواند به بهبود عملکرد کمک کند، به‌ویژه زمانی که داده‌ها کمیاب هستند. یادگیری انتقالی همچنین می‌تواند برای کمک به مدل‌ها برای تعمیم بهتر به جفت‌های هدف دارو یا کلاس‌های جدیدی از داروها، تعمیم بهتر مدل‌ها مورد بررسی قرار گیرد، و به مسائل مربوط به تطبیق بیش از حد مدل در مجموعه‌های داده کوچک‌تر رسیدگی شود.

از نظر تفسیرپذیری مدل، بهبود توضیح‌پذیری پیش‌بینی‌های قرابت دارو-هدف یکی دیگر از جهت‌های مهم است. مدل‌های یادگیری عمیق، اگرچه قدرتمند هستند، اغلب به عنوان جعبه‌های سیاه دیده می‌شوند. برای کشف و استفاده مجدد از دارو، نه تنها پیش بینی تداخلات، بلکه همچنین درک اینکه چرا داروهای خاص به اهداف خاصی متصل می شوند، بسیار مهم است. ترکیب تکنیک‌های هوش مصنوعی قابل توضیح (XAI) در مدل‌های هدف دارو می‌تواند کاربرد آن‌ها را در کاربردهای دنیای واقعی افزایش دهد. تکنیک‌هایی مانند مکانیسم‌های توجه یا انتشار ربط لایه‌ای (LRP) می‌توانند بینشی در مورد ویژگی‌هایی (به عنوان مثال، مناطق خاصی از پروتئین یا ساختارهای مولکولی دارو) ارائه دهند که پیش‌بینی‌های مدل را هدایت می‌کنند. این می‌تواند برای محققانی که به دنبال درک مکانیسم‌های بیولوژیکی زیربنایی هستند بسیار ارزشمند باشد و اعتماد به پیش‌بینی‌های مدل‌ها، به‌ویژه در کاربردهای بالینی را افزایش دهد.

در نهایت، یک منطقه هیجان انگیز برای تحقیقات آینده، استفاده از یادگیری تقویتی (RL) در پیش بینی میل ترکیبی دارو-هدف است. RL می‌تواند برای بهینه‌سازی انتخاب داروها با کاوش در فضاهای شیمیایی وسیع و انتخاب مولکول‌هایی که میل ترکیبی را به حداکثر می‌رسانند در حالی که خواص نامطلوب مانند سمیت را به حداقل می‌رسانند، مورد استفاده قرار گیرد. ترکیب RL با مدل‌های یادگیری عمیق مانند DTANet می‌تواند طراحی ترکیبات کاملاً جدید را با فعل و انفعالات دارویی-هدف بهینه‌سازی شده را امکان‌پذیر کند، که فراتر از پیش‌بینی به طراحی دارو پیش می‌رود.

# مراجع


[1] Mullard, Asher. “New drugs cost US$2.6 billion to develop.” *Nature Reviews Drug Discovery* 13 (2014): 877-877.

[2] Ashburn, Ted T, and Karl B Thor. “Drug repositioning: identifying and developing new uses for existing drugs.” *Nature reviews. Drug discovery* vol. 3,8 (2004): 673-83. doi:10.1038/nrd1468

[3] Strittmatter, Stephen M. “Overcoming Drug Development Bottlenecks with Repurposing: Old drugs learn new tricks.” *Nature medicine* vol. 20,6 (2014): 590-1. doi:10.1038/nm.3595

[4] Gordon, David, et al. “A SARS-CoV-2 Protein Interaction Map Reveals Targets for Drug Repurposing.” *Nature*, vol. 583, no. 7816, Apr. 2020, pp. 459–68. doi.org/10.1038/s41586-020-2286-9.

[5] Cohen, Philip. “Protein Kinases — the Major Drug Targets of the Twenty-first Century?” *Nature Reviews Drug Discovery*, vol. 1, no. 4, Apr. 2002, pp. 309–15. doi.org/10.1038/nrd773.

[6] Deshpande, M., et al. “Frequent substructure-based approaches for classifying chemical compounds.” *IEEE Transactions on Knowledge and Data Engineering*, vol. 17, no. 8, Aug. 2005, pp. 1036–50. doi.org/10.1109/tkde.2005.127.

[7] Li, Jin et al. “An Overview of Scoring Functions Used for Protein-Ligand Interactions in Molecular Docking.” *Interdisciplinary sciences, computational life sciences* vol. 11,2 (2019): 320-328. doi:10.1007/s12539-019-00327-w

[8] He, Tong, et al. “SimBoost: A Read-across Approach for Predicting Drug–target Binding Affinities Using Gradient Boosting Machines.” *Journal of Cheminformatics*, vol. 9, no. 1, Apr. 2017, doi.org/10.1186/s13321-017-0209-z.

[9] Cichonska, Anna et al. “Learning with multiple pairwise kernels for drug bioactivity prediction.” *Bioinformatics (Oxford, England)* vol. 34,13 (2018): i509-i518. doi:10.1093/bioinformatics/bty277

[10] Öztürk, Hakime et al. “DeepDTA: deep drug-target binding affinity prediction.” *Bioinformatics (Oxford, England)* vol. 34,17 (2018): i821-i829. doi:10.1093/bioinformatics/bty593

[11] Sigrist, Christian J A et al. “PROSITE, a protein domain database for functional characterization and annotation.” *Nucleic acids research* vol. 38, Database issue (2010): D161-6. doi:10.1093/nar/gkp885

[12] Öztürk, Hakime, et al. “WideDTA: Prediction of Drug-target Binding Affinity.” *arXiv (Cornell University)*, Jan. 2019, doi.org/10.48550/arxiv.1902.04166.

[13] Mayr, Andreas, et al. “Large-scale Comparison of Machine Learning Methods for Drug Target Prediction on ChEMBL.” *Chemical Science*, vol. 9, no. 24, Jan. 2018, pp. 5441–51. doi.org/10.1039/c8sc00148k.

[14] Nguyen, Thin et al. “GraphDTA: predicting drug-target binding affinity with graph neural networks.” *Bioinformatics (Oxford, England)* vol. 37,8 (2021): 1140-1147. doi:10.1093/bioinformatics/btaa921

[15] Liu, Ziming, et al. “KAN: Kolmogorov-Arnold Networks.” *arXiv (Cornell University)*, Apr. 2024, doi.org/10.48550/arxiv.2404.19756.

[16] Labonne, Maxime. *Graph Neural Networks: Unlock a Whole New Range of Deep Learning Applications with Graph Data*. Packt Publishing, 2023.

[17] Zhang, Fan, and Xin Zhang. “GraphKAN: Enhancing Feature Extraction With Graph Kolmogorov Arnold Networks.” *arXiv (Cornell University)*, June 2024, doi.org/10.48550/arxiv.2406.13597.

[18] Kiamari, Mehrdad, et al. “GKAN: Graph Kolmogorov-Arnold Networks.” *arXiv (Cornell University)*, June 2024, doi.org/10.48550/arxiv.2406.06470.

[19] Weininger, David. “SMILES, a Chemical Language and Information System. 1. Introduction to Methodology and Encoding Rules.” *Journal of Chemical Information and Computer Sciences*, vol. 28, no. 1, Feb. 1988, pp. 31–36. doi.org/10.1021/ci00057a005.

[20] Ramsundar, Bharath, et al. *Deep Learning for the Life Sciences: Applying Deep Learning to Genomics, Microscopy, Drug Discovery, and More*. 2019.

[21] Davis, Mindy I., et al. “Comprehensive Analysis of Kinase Inhibitor Selectivity.” *Nature Biotechnology*, vol. 29, no. 11, Oct. 2011, pp. 1046–51. doi.org/10.1038/nbt.1990.

[22] Tang, Jing et al. “Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis.” *Journal of chemical information and modeling* vol. 54,3 (2014): 735-43. doi:10.1021/ci400

[23] Wikipedia contributors. “Simplified Molecular Input Line Entry System.” Wikipedia, 23 Aug. 2024, en.wikipedia.org/wiki/Simplified_Molecular_Input_Line_Entry_System.

[این صفحه خالی است]

# Abstract

From the past until now, the design and development of drugs have always faced many challenges, such as time-consuming, expensive, and challenges related to drug safety. Drug repurposing is one of the approaches to dealing with these challenges. In this method, it seems necessary to identify which proteins related to the pathogenic agent are affected by the drug in question. This problem is also known as drug-target affinity prediction.

To solve this problem, many computational methods have been used, among which artificial intelligence and deep learning methods can be mentioned. In this project report, a deep neural network called DTANet is introduced. This neural network is used to predict drug-target relationships and uses MLP, CNN, and GraphKAN architectures (derived from Kolmogorov-Arnold neural network).

This neural network has been able to perform better than several previous models such as GraphDTA: GCN and WideDTA in the evaluation metrics related to the two datasets of this problem and appears at performance level of a powerful neural network such as GraphDTA: GAT, which uses the Attention mechanism.

**Implementation Availability:** The proposed model is implemented in Python programming language with the help of libraries such as PyTorch, PyTorch Geometric, etc. Related data, results, pre-trained model, and source code related to this project are published on GitHub at https://github.com/kourosh-y/DTANet.

**Keywords:** Drug repurposing; drug-target affinity; Deep learning




Babol Noshirvani University of Technology

Faculty of Electrical and Computer Engineering

*A Thesis*

*Submitted in Partial Fulfillment of the Requirement for the Bachelor Degree of Science in*

Computer Engineering

# Implementation and analysis of a model for drug-target affinity using Deep learning

by:

**Kourosh Yousofian**

Supervisor:

**Dr. Zamani**

**August 2024**